Agente IA 4.0.2

Manual de usuario

Oficina de IA local para pymes

Manual de usuario

Nexus-Office 2.2: la versión de referencia
- Comparación con la 1.8.1
- Lo nuevo de la 2.2
- Qué no se ha podido probar sin hardware real

Guía de usuario
- Instalación
  - Windows
  - Linux (PC, Steam Deck, Raspberry Pi)
  - macOS
  - Android
- Modelo de IA elegido según tu equipo
- Arranque automático
- Descargar los instaladores desde el móvil
- Uso diario (modo sencillo)
  - La barra superior
  - Chat
  - El avatar
  - Salón
  - Núcleo
  - Estudio
  - Bolsa
  - Modelos
  - Ajustes
  - Profesor (IA online)
  - Dispositivos: luces, reloj y Pico W
  - Motor y acelerador
  - Leer páginas web como un navegador
  - Usarlo desde el móvil, tablet o consola

Oficina para pymes: perfiles por gremio
- Cada agente tiene su propio grafo
- Perfiles incluidos
  - Modelos de IA sugeridos para cada sector
- Elegir un perfil
- Sin internet
- Crear o ampliar perfiles
- Paquetes de conocimiento

Oficina de bolsa e inversiones y mesa simulada
- Datos reales (2.1)
- Agente de bolsa autónomo (2.1)
- Agentes
- La mesa simulada
- Cartera real: nunca sin tu confirmación
- Terminal
- API

Nexus-Office como servicio: arranque automático
- Cómo se activa
- Comandos
- Qué hace en cada sistema
- App Nexus-Office autónomo (Android)
- Quitar el servicio
- Registro (logs)

- Problemas frecuentes

Avatares
- Encuadre automático (2.0)
- Encuadre en el chat (2.2)
- Biblioteca de avatares 3D gratuitos (2.2)
- Crear un avatar de calidad a partir de imágenes
  - Imágenes de referencia necesarias
  - Regenerar el avatar con otra hoja de personaje

Salón virtual de agentes
- Despachos (2.2)
- Personajes: mujer u hombre (2.2)
- Qué se registra
- Directorio de habilidades
- Reuniones

Motor de IA y acelerador (CPU, GPU o NPU)
- Dónde se elige
- Perfiles de hardware (2.2)
- Equipos con dos o más GPU y Linux (2.2)
- Motores
- Aceleradores
- Cómo se comprueba que acelera de verdad
- Runtimes incluidos por instalador
- Configuración

Motores de inferencia por hardware
- Motores
- Android (APK autónoma), desde la 4.0.2
- Qué motor va con cada chip
- El banco manda sobre la tabla
- Aceleradores y caídas
- Modelos para cada motor
- Pruebas

Importar grafos como conocimiento
- Cómo se importa
  - Desde la app
  - Desde la terminal
  - Desde el chat
  - Dentro de un ZIP
- Formatos admitidos
- Qué se guarda de cada grafo
- Para desarrolladores

Biblioteca RAG y conversión URL → PDF
- RAG (generación aumentada por recuperación)
- Leer páginas como un navegador (2.2)
- Grafo general o grafo de un agente
- Archivos ZIP, RAR, 7z y TAR con proyectos o documentación
- Rendimiento: procesador al máximo
- Rastreo (crawling) de un sitio de documentación
  - Todo el dominio, sin excepciones (2.0)
  - Dominios enteros: rastreo por lotes
- URL → PDF estructurado → conocimiento

Dispositivos: luces, reloj y avatar de bolsillo
- Grabar el firmware
- Luces NexusLED
- Reloj NexusWatch

Avatar NexusPico
Modos
API
Qué no se ha podido probar sin el hardware

Nexus-Office 2.2: la versión de referencia

La 2.2 junta en una sola versión todo lo que se ha hecho desde la 1.8.1 (GIMP para los agentes) en Windows, Linux, macOS y Android: lo de la 1.9 y la 2.0, lo que se hizo para la edición C++ 2.1 y lo nuevo de la 2.2. Esta página compara la 2.2 con la 1.8.1, apartado por apartado.

No se ha quitado nada de la 1.8.1. Comparando el código de las dos versiones, no se ha borrado ningún fichero de la aplicación, siguen todas las secciones de la interfaz (11 en la 1.8.1, 12 ahora con Dispositivos) y siguen los cinco agentes de serie, más el Profesor. Las pruebas automáticas han pasado de 33 a 46 ficheros.

Comparación con la 1.8.1

Apartado	1.8.1	2.2
Instaladores	CPU, con GIMP dentro	CPU, GPU y NPU en el mismo paquete offline: llama-server con CUDA, Vulkan, Metal u OpenVINO y llama.cpp integrado, con GIMP y ahora también el firmware de los dispositivos y los ejemplos para importar
Motor y acelerador	Automático, sin elección	Ventana al arrancar para elegir motor y CPU/GPU/NPU, **PROBAR** con tokens por segundo y dónde ha quedado el modelo (ACELERADOR.md)
Perfiles de hardware	—	Seis de serie y los tuyos: motor, modelo, contexto, capas en la GPU y caché KV en VRAM o RAM
Varias GPU y Linux	Podía usar la integrada o llvmpipe (más lento que la CPU)	`--device` con la GPU elegida, sin dispositivos de software, vuelta a la CPU si la GPU falla
Barra superior	Indicadores fijos	Menús IA, PERFIL, MEMORIA y RED con lo que tu equipo tiene de verdad
Modelos	Qwen3	Qwen3.5 con razonamiento y visión, e IA de apoyo semántica para las herramientas
Chat	Texto, voz, imágenes	Además **modo en vivo** manos libres e interrumpir hablando
Profesor	—	Agente con IA online opcional (Gemini, ChatGPT, Perplexity, Claude, Mistral…); los demás le preguntan y aprenden
Bolsa	Mesa simulada con precios ficticios	Simulación **con cotizaciones reales** (Yahoo, CNBC, Google, Stooq, Coinbase, Kraken), **agente de bolsa autónomo** con su cartera simulada, diario y gráficos en vivo de sus órdenes. Nunca dinero real (BOLSA.md)
Grafos	Grafo propio	Importar grafos de más de 50 formatos (Gephi, Neo4j, RDF, Excel…) como conocimiento, en todas las plataformas, y grafo de ejemplo de la Wikipedia en español (GRAFOS.md)
Biblioteca RAG	Documentos y rastreo	Además dominios enteros con grafo multicapa y **lectura como un navegador** de webs hechas con JavaScript (RAG.md)
Avatar	Geisha, grafo, modelo propio	Encuadre automático de modelos de cualquier tamaño (también en el chat) y **biblioteca de avatares 3D gratuitos** (Open Source Avatars, VRM Consortium, Khronos, three.js, Sketchfab) (AVATAR.md)
Salón	Mesa con los agentes	Personajes más realistas, reuniones sin solapes, **despachos animados** con lo que hace cada agente y **sexo elegible** de cada personaje, tú incluido (SALON.md)
Dispositivos	—	Luces NexusLED para cualquier ESP32, reloj NexusWatch (ESP32-2424S012C), avatar NexusPico (Pico W, pantalla del pwnagotchi), modos y grabado sin internet (DISPOSITIVOS.md)
Android	Dos apps: autónoma (CPU/GPU, NPU experimental) y VPN	**Una sola app**: la IA en el móvil (NPU, GPU o CPU) y *Conectar a mi ordenador* por red local, internet o VPN WireGuard. La app VPN ligera sigue para móviles modestos
Edición C++	—	Nexus-Office 2.1 en C++, un solo ejecutable con las mismas respuestas de la API (CPP.md)

Lo nuevo de la 2.2

- **Perfiles de hardware** y **elección de GPU**, con el arreglo de la aceleración en Linux y de los equipos con dos GPU.
- **Barra superior con menús** que dependen del hardware.
- **RAG que lee páginas como un navegador**, con un navegador sin ventana del propio equipo, perfil propio y salida solo a direcciones públicas.
- **Despachos** animados por agente y **sexo** de cada personaje.

- **APK única** con la IA del móvil y la conexión al ordenador, con VPN WireGuard.
- **Avatares**: el chat encuadra los modelos grandes y hay biblioteca de avatares 3D gratuitos.
- **Bolsa**: gráficos reales de cripto aunque Yahoo limite (Coinbase y Kraken) y de acciones (CNBC).
- **Firmware y ejemplos dentro de los instaladores**.

Qué no se ha podido probar sin hardware real

- Dos GPU físicas en el mismo equipo y la NPU de Intel (OpenVINO) y de Snapdragon (Hexagon): la lógica está probada con salidas reales de `--list-devices`, pero no con las tarjetas.
- El firmware en las placas reales (ver DISPOSITIVOS.md).
- La APK en un móvil físico: compila en CI y la IA del móvil se probó en un Android emulado (2.0), pero no la NPU, la GPU del móvil ni la nueva conexión al ordenador (red local, internet y VPN) contra un PC real.

Guía de usuario

Esta guía explica cómo instalar Nexus-Office en cada equipo y cómo usarlo en el día a día. Para la configuración avanzada, ver la guía de administrador; para montar la oficina de tu empresa, Oficina para pymes.

Instalación

Todos los instaladores son **100 % portables**: llevan dentro Python, todo lo que necesita Nexus-Office y el motor de IA (llama-server y sd-cli, para CPU y para la tarjeta gráfica). **Se instalan sin internet.** Lo único que se descarga es el modelo de IA, elegido según tu equipo, y solo si hay conexión (ver más abajo).

Elige el fichero de tu equipo (versión 2.2.0):

Equipo	Fichero
PC con Windows 10/11 de 64 bits (Intel o AMD)	`windows/Nexus-Office-Setup-2.2.0-windows-x64.exe`
PC con Windows 11 en ARM (Snapdragon X)	`windows/Nexus-Office-Setup-2.2.0-windows-arm64.exe`
PC con Linux (Ubuntu, Debian, Fedora, Steam Deck…)	`linux/Nexus-Office-2.2.0-linux-x86_64.run`, `.AppImage` o `.flatpak`; en Debian y Ubuntu también `linux/nexus-office_2.2.0_amd64.deb`
Raspberry Pi 4/5 y otros Linux ARM de 64 bits	`linux/Nexus-Office-2.2.0-linux-aarch64.run`, `.AppImage`, `.flatpak` o `linux/nexus-office_2.2.0_arm64.deb`
Mac con Apple Silicon (M1, M2, M3…)	`macos/Nexus-Office-2.2.0-macos-arm64.tar.gz`
Mac con Intel	`macos/Nexus-Office-2.2.0-macos-x86_64.tar.gz`
Móvil Android: Nexus-Office dentro del móvil y conexión al PC de la oficina	`android/Nexus-Office-2.2.0-android-autonomo.apk`
Móvil Android modesto: solo usar el Nexus-Office del PC	`android/Nexus-Office-2.2.0-android-vpn.apk`

`SHA256SUMS.txt` trae la huella de cada fichero, para comprobar que se ha copiado bien. Si Nexus-Office ya está instalado en un PC de la oficina, los demás equipos y móviles pueden descargar su instalador desde él (ver Descargar los instaladores desde el móvil).

Windows

1. Haz doble clic en `Nexus-Office-Setup-2.2.0-windows-x64.exe` (o `-arm64.exe` en un PC con Snapdragon X).
2. El instalador no está firmado. Si Windows muestra «Windows protegió su PC», pulsa **Más información → Ejecutar de todas formas**.
3. Acepta la licencia y elige la carpeta. Por defecto es `%LOCALAPPDATA%\Nexus-Office` y no hace falta ser administrador. La carpeta es portable: puedes elegir un disco USB.
4. En la página **Opciones** eliges: - **Perfil de oficina**: el tipo de empresa (herrería, calderería, reformas…), o *ninguno* para los agentes generales. Se puede cambiar después en *Agentes → Perfil de oficina*. - **Elegir y descargar el modelo de IA adecuado a este equipo** (necesita internet). - **Arrancar Nexus-Office como servicio al encender el equipo**: solo este paso pide permiso de administrador. Si no lo das, Nexus-Office arranca al iniciar sesión. Ver Arranque automático. - **Accesible desde la red local**, para entrar desde los móviles y los otros PC de la oficina. - **Crear acceso directo en el escritorio**.
5. Al terminar, marca **Abrir Nexus-Office**. Se abre el navegador en `http://127.0.0.1:8775`.

En el menú Inicio quedan *Nexus-Office*, *Nexus-Office (consola)* (la misma aplicación, con una ventana de registro), el *Manual de usuario* y *Desinstalar Nexus-Office*. Nexus-Office aparece también en *Configuración → Aplicaciones*. Al desinstalar, se quita el servicio y te pregunta si borras también tus datos (conversaciones, documentos, modelos y configuración); si dices que no, quedan en la carpeta `data`.

Instalación desatendida (por ejemplo, en varios PC):

```
Nexus-Office-Setup-2.2.0-windows-x64.exe /S /OFICINA=herreria /SERVICIO /RED /MODELOS=auto /D=C:\Nexus-Office
```

Opción	Qué hace
`/S`	Sin ventanas.
`/OFICINA=<perfil>`	Perfil de oficina (lista en OFICINA.md).

Opción	Qué hace
`/SERVICIO`	Arranque automático. Pide permiso de administrador salvo que el instalador ya se ejecute como administrador.
`/RED`	El servicio escucha en la red local.
`/MODELOS=auto|todos|no`	`auto` (por defecto): modelo de chat, documentos y voz; `todos`: también el de imagen; `no`: no descarga nada.
`/D=<carpeta>`	Carpeta de instalación. Va siempre la última.

Linux (PC, Steam Deck, Raspberry Pi)

Con el instalador `.run` (cualquier distribución):

```
sh Nexus-Office-2.2.0-linux-x86_64.run                  # en Raspberry Pi y ARM: Nexus-Office-2.2.0-linux-
aarch64.run
sh Nexus-Office-2.2.0-linux-x86_64.run ~/Nexus-Office --oficina=herreria --servicio --red
```

Se instala en `~/.local/share/nexus-office` si no indicas otra carpeta. Opciones:

- `--oficina=<perfil>`: perfil de oficina.
- `--modelos=auto|todos|no`: igual que en Windows.
- `--servicio`: arranque automático, como servicio de tu usuario que arranca al encender el equipo (si el sistema permite `loginctl enable-linger`; si no, al iniciar sesión). Con `sudo` se instala para todo el equipo en `/opt/nexus-office` (a nombre de tu usuario) y el servicio es del sistema: `sudo sh Nexus-Office-2.2.0-linux-x86_64.run --servicio --red`.
- `--red` (junto con `--servicio`): el servicio escucha en la red local.

Después, abre *Nexus-Office* desde el menú de aplicaciones o ejecuta `start.sh` en la carpeta de instalación. En Steam Deck, instálalo en modo escritorio y añade `start.sh` como *juego no-Steam*.

Con AppImage (cualquier distribución, sin instalar nada): un único fichero que se ejecuta tal cual. Nexus-Office ya va instalado dentro; tus datos quedan en `~/.local/share/nexus-office`.

```
chmod +x Nexus-Office-2.2.0-linux-x86_64.AppImage      # en Raspberry Pi y ARM: Nexus-Office-2.2.0-linux-
aarch64.AppImage
./Nexus-Office-2.2.0-linux-x86_64.AppImage              # arranca Nexus-Office y abre el navegador
./Nexus-Office-2.2.0-linux-x86_64.AppImage oficina herreria
./Nexus-Office-2.2.0-linux-x86_64.AppImage servicio instalar --red   # arranque automático (usa la ruta del
AppImage: no lo muevas después)
```

Si tu sistema no tiene FUSE (aparece «libfuse.so.2 not found»), ejecútalo con `--appimage-extract-and-run` delante de los argumentos, o instala `libfuse2`.

Con Flatpak (Fedora, Ubuntu, Linux Mint, Steam Deck...): la primera vez descarga de Flathub el runtime `org.freedesktop.Platform 24.08` (si no lo tienes ya).

```
flatpak install --user Nexus-Office-2.2.0-linux-x86_64.flatpak     # o -aarch64.flatpak
flatpak run ai.nexus.NexusOffice                                   # o desde el menú de aplicaciones
flatpak run ai.nexus.NexusOffice servicio instalar                 # deja lista la unidad; actívala con:
systemctl --user enable --now nexus-office
```

Los datos quedan en `~/.var/app/ai.nexus.NexusOffice/data/nexus-office`.

Con el paquete `.deb` (Debian, Ubuntu, Linux Mint, Raspberry Pi OS de 64 bits):

```
sudo apt install ./nexus-office_2.2.0_amd64.deb         # en Raspberry Pi y ARM: nexus-office_2.2.0_arm64.deb
nexus-office                                            # arranca Nexus-Office y abre el navegador
sudo nexus-office servicio instalar --red               # opcional: arranque automático accesible desde la red
```

El programa queda en `/opt/nexus-office` y los datos de cada usuario en `~/.local/share/nexus-office`. La primera vez que lo abres, evalúa el hardware y descarga el modelo de IA si hay internet. Se desinstala con `sudo apt remove nexus-office`, que quita también el servicio; tus datos se conservan.

Raspberry Pi: hace falta una Raspberry Pi 4 o 5 con **sistema de 64 bits** (Raspberry Pi OS 64-bit o Ubuntu) y mejor con 4 GB de RAM o más. Los sistemas de 32 bits no están soportados. Guarda los modelos en un disco SSD o USB 3 si puedes: cargan mucho más rápido que desde la tarjeta SD.

macOS

1. Descomprime `Nexus-Office-2.2.0-macos-arm64.tar.gz` (o `-macos-x86_64` en un Mac con Intel) donde quieras.
2. Abre **Nexus-Office.command**. Como no está firmado por Apple, la primera vez haz **clic derecho → Abrir** y confirma.
3. La primera vez se prepara Nexus-Office (sin internet salvo para el modelo de IA) y después se abre el navegador.

Desde la terminal también puedes elegir las opciones:

```
./install.sh --oficina=herreria --servicio && ./start.sh
```

Android

Desde la 2.2 hay **una sola app** para todo, `Nexus-Office-2.2.0-android-autonomo.apk` (Android 9 o superior, ARM64):

- **Nexus-Office en el móvil**, sin PC y sin conexión. La APK lo lleva todo y solo descarga el modelo de IA adecuado a la RAM del móvil (Qwen3-VL 2B o 4B Thinking). Detecta la CPU, la GPU y la NPU: en los Snapdragon 8 Gen 2 o posteriores pone el modelo en la NPU; si no hay NPU utilizable o falla, en la GPU (Adreno, Mali, Immortalis, Xclipse…), y si tampoco, en la CPU. Lo ves en *Sistema → Hardware* y en el menú **IA** de la barra superior. Ver su guía.
- **Motores de IA en el móvil** (desde la 4.0.2): además de llama.cpp, la app trae Qualcomm Genie (NPU Hexagon de los Snapdragon), LiteRT-LM (NPU de Snapdragon, Tensor y Dimensity, y GPU), ONNX Runtime GenAI (NPU por QNN o CPU) y ExecuTorch. En *Sistema → Motores* ves cuáles están listos; TensorRT-LLM, OpenVINO y MLC aparecen aparte como «no aplican a este equipo» porque son para gráficas NVIDIA, procesadores Intel o necesitan compilar cada modelo. Para usar la NPU descarga un modelo de motor del catálogo (por ejemplo *Gemma 4 E2B · LiteRT-LM*, que se baja en la versión para tu chip si existe) o importa una carpeta de Qualcomm AI Hub para Genie.
- **Conectar a mi ordenador**: en el menú **RED** de la barra superior. Abre el Nexus-Office de tu PC (Windows, Linux o macOS) en la Wi-Fi, desde internet con un código `NEXUSR1:` o por **VPN cifrada WireGuard** con un código `NEXUSV1:` (en el PC: *Red COOP → VPN cifrada → GENERAR CÓDIGO VPN*). El botón **USAR NEXUS-OFFICE EN ESTE MÓVIL** vuelve a la IA del teléfono. Ver VPN y Acceso remoto.

Se sigue publicando la app ligera `Nexus-Office-2.2.0-android-vpn.apk` (Android 7 o superior) para móviles que no pueden con la IA local y solo quieren usar la del PC.

1. Copia la APK al móvil o descárgala desde el PC de la oficina (*Sistema → Descargas*) o desde la web de descargas.
2. Ábrela. Android pedirá permiso para **instalar apps desconocidas** desde esa app (el navegador o el gestor de archivos): concédelo.
3. Si tenías una autónoma anterior a la 2.0 o la app Nexus-Office 1.3, desinstálala antes: estaban firmadas con otra clave. Desde la 2.0 se actualiza encima sin perder nada.

Modelo de IA elegido según tu equipo

Al instalar, Nexus-Office **evalúa el hardware** (memoria, tarjeta gráfica, procesador) y elige el mejor modelo de cada tipo que funciona con fluidez en ese equipo:

Tipo	Para qué	Modelos posibles
Chat y visión	Conversar, razonar y entender imágenes	Qwen3-VL 2B Thinking (1,5 GB, desde 3 GB de RAM), 4B (2,8 GB) u 8B (5,5 GB, con GPU de 8 GB o más)
Documentos	Buscar y ordenar tu biblioteca y la memoria	Qwen3-Embedding 0.6B (639 MB)
Voz	Leer las respuestas en voz alta	Piper, voz española (61 MB)
Imagen	Generar imágenes (solo con la opción *todos*)	SDXS-512 en CPU; SD-Turbo o SDXL-Turbo con más memoria o GPU

Si hay internet, los descarga al momento. **Sin internet**, el instalador solo muestra la recomendación y Nexus-Office funciona igualmente con su núcleo integrado (herramientas, memoria, imagen compuesta a partir del prompt, música y la voz del navegador). Los modelos se descargan después, cuando haya red, desde **Modelos → Recomendados** (el marcado con ★) o desde la terminal:

```
venv/bin/python3 -m nexus modelos                  # muestra el equipo y el modelo elegido de cada tipo
venv/bin/python3 -m nexus modelos --descargar      # y los descarga (chat, documentos y voz)
venv/bin/python3 -m nexus modelos --descargar --todos   # también el de imagen
```

En Windows, `venv\python.exe` en lugar de `venv/bin/python3`; con el `.deb`, `nexus-office modelos --descargar`.

Arranque automático

Con el **arranque automático**, Nexus-Office se inicia solo al encender el equipo, sin ventana, y se reinicia si falla. Es lo recomendable en el PC de la oficina, para que los móviles y los demás equipos lo encuentren siempre.

- Se activa al instalar (opción *Arrancar Nexus-Office como servicio* en Windows, `--servicio` en Linux y macOS) o después, en **Sistema → Arranque automático → INSTALAR SERVICIO** (modo administrador). Marca *accesible desde la red local* si lo vas a usar desde otros dispositivos.
- Con el servicio en marcha, el acceso directo solo abre el navegador: no arranca un segundo Nexus-Office.
- En la app **Nexus-Office autónomo**: *Sistema → Arranque automático* → **ARRANCAR AL ENCENDER**.
- Para quitarlo: **QUITAR** en el mismo panel (o **DESACTIVAR** en la app). Nexus-Office sigue instalado.

Detalles por sistema, comandos y problemas frecuentes: Servicio.

Descargar los instaladores desde el móvil

El PC de la oficina puede repartir los instaladores a los demás equipos y móviles de la red, sin cables ni memorias USB:

1. En el PC donde corre Nexus-Office, copia la carpeta de instaladores (`windows/`, `linux/`, `macos/`, `android/`…) dentro de la carpeta `descargas` de los datos de Nexus-Office: `data/descargas/` (con el `.deb`, `~/.local/share/nexus-office/descargas/`). La ruta exacta aparece en el panel mientras está vacío.
2. Nexus-Office tiene que ser accesible desde la red: servicio con *accesible desde la red local*, o *Red COOP → Conectar dispositivos → Permitir acceso desde la red*.
3. Desde el móvil o el otro PC, abre Nexus-Office (en el navegador con la clave de red, o con la app Nexus-Office VPN) y ve a **Sistema → Descargas**.

La lista marca con **anfitrión** el instalador del equipo donde corre Nexus-Office y con **este dispositivo** el que corresponde al móvil o PC desde el que miras. Pulsa **DESCARGAR**. En la app Android, eliges dónde guardar el fichero; después ábrelo para instalarlo.

Uso diario (modo sencillo)

El modo **USUARIO** (arriba a la derecha) muestra solo lo necesario. Nada de lo que hagas en este modo puede romper la configuración avanzada.

La barra superior

Las cuatro píldoras de arriba son menús que se abren con un toque y muestran lo que tu equipo tiene de verdad:

- **IA**: el motor (llama.cpp, el integrado, Ollama, LM Studio…), dónde corre (CPU, GPU o NPU, solo las que hay) y el modelo activo. Con **dos o más GPU** eliges en cuál va el modelo; las tarjetas «de software» (llvmpipe, lavapipe, SwiftShader) no aparecen porque irían más lentas que la CPU.
- **PERFIL**: el perfil de hardware (*Automático*, *Rendimiento*, *Equilibrado*, *Modelo grande*, *Ahorro*, *Solo CPU* o los tuyos). Cada perfil fija motor, acelerador, modelo, contexto, capas en la GPU y si la memoria de la conversación (caché KV) va en la VRAM o en la RAM. **Editar perfiles** crea o cambia los tuyos.
- **MEMORIA**: el modelo de *embeddings*, cuánto sabe Nexus-Office y cómo lee las páginas web (*Automático*, *Siempre como navegador* o *Nunca*).
- **RED**: la red COOP, el acceso desde la red local y, en el móvil, **Conectar a mi ordenador**.

En el móvil el menú se abre a pantalla completa con pestañas.

Chat

- Escribe y pulsa **Enter** (Shift+Enter = nueva línea). El selector de la izquierda elige agente; *Automático* deja que Nexus-Office decida.

- 📎 adjunta imágenes (también puedes pegarlas): Nexus-Office las describe, lee texto (OCR) y responde preguntas sobre ellas.
- 🎤 habla; 🔊 activa la lectura en voz alta de las respuestas.
- **Modo en vivo** (botón de ondas junto al micrófono): conversación por voz manos libres. Hablas, Nexus-Office te escucha, responde en voz alta y vuelve a escuchar. Si hablas mientras responde, se calla y te atiende (*interrumpir hablando*). **PAUSAR** y **TERMINAR** abajo. Para ir rápido responde sin razonar y en frases cortas (como máximo `live.max_tokens`, 400 por defecto; `live.reasoning: true` le deja razonar un poco). Escucha con Whisper local si está instalado, con la voz del sistema en la app Android o con el reconocimiento del navegador (Chrome, Edge, Safari). El micrófono del navegador solo funciona en este mismo equipo o por https.
- Bajo cada respuesta: 👍 / 👎 enseñan a Nexus-Office qué te gusta (aprende ejemplos, lecciones y la longitud preferida), 🔊 lee, ⧉ copia.
- Las líneas verdes "✧ aprendido" muestran lo que acaba de memorizar de ti.
- Si un agente necesita una herramienta con riesgo, aparece una tarjeta **APROBACIÓN REQUERIDA**: tú decides.

Prueba: *«Me llamo Ane y me gusta el surf»*, *«¿Qué sabes de mí?»*, *«Genera una imagen de un faro bajo la tormenta»*, *«Compón una música relajante»*, *«Cuánto es 2^16 / 7»*.

El avatar

A la derecha del chat está el **núcleo cognitivo**: cada punto es algo que Nexus-Office ha aprendido (personas, lugares, gustos, conceptos) y las líneas son relaciones. Cambia de color según su estado: cian (en línea), violeta (pensando), ámbar (herramienta), magenta (hablando, late con la voz), verde (escuchando).

En *Ajustes > Avatar* puedes **buscar y descargar avatares 3D gratuitos** de Internet: cientos de avatares VRM de Open Source Avatars (casi todos CC0), los modelos de referencia de VRM Consortium, Khronos y three.js, y modelos con licencia Creative Commons de Sketchfab (para descargar de Sketchfab hace falta la clave de API gratuita de tu cuenta). Lo descargado queda en tu equipo con su autor y su licencia, y se puede elegir como avatar en cualquier momento, también sin conexión.

El avatar 3D se encuadra solo, sea del tamaño que sea el modelo descargado: en el chat siempre se ve entero dentro de su hueco. Ver AVATAR.md.

Salón

Representación gráfica de los agentes reunidos. Mira cómo conversan, cómo se delegan tareas y qué habilidades han demostrado. Pulsa **Convocar reunión** o escribe algo en el salón. Mientras dura una reunión el botón muestra *REUNIÓN EN CURSO...* y no se puede convocar otra encima. La **Transcripción** recoge todo lo dicho y funciona igual en ordenador, móvil y tableta.

La pestaña **DESPACHOS** muestra a cada agente en su despacho haciendo lo que hace de verdad en ese momento: piensa con un café, escribe, busca en internet, lee, dibuja con el lápiz, compone con los cascos, habla por teléfono con el Profesor o sale por la puerta hacia la reunión del salón. La ventana sigue la hora real y la pantalla de la pared muestra el trabajo en curso.

Cada personaje, **tú incluido**, puede ser mujer u hombre: el de cada agente en *Agentes → editar → Sexo* y el tuyo en *Ajustes → Tu personaje*. Cambia peinado, complexión, barba, pestañas y labios. Ver SALON.md.

Núcleo

Explora tu grafo de conocimiento en 3D (arrastra para girar, rueda para acercar), busca recuerdos, borra los que no quieras y enséñale datos nuevos.

Estudio

Genera imágenes y música, analiza imágenes y revisa la galería.

Bolsa

Mesa de bolsa **simulada** para practicar sin dinero: cartera ficticia de 10.000 €, órdenes a mercado, limitadas y stop, comisiones, impuestos, cambio de divisa y deslizamiento. **Con conexión, los precios son cotizaciones reales** (Yahoo Finance, con el retraso de cada bolsa; CNBC, Google Finance, Stooq, Coinbase y Kraken de respaldo, también para los gráficos) y el cambio de divisa es el real; sin conexión la mesa sigue simulada desde el último precio real, solo con la bolsa abierta (en su hora local y con sus festivos). Nunca se usa dinero ni se envían órdenes reales, y nada de esto es asesoramiento financiero.

El **agente de bolsa autónomo** gestiona su propia cartera simulada con esos datos reales: analiza cada valor (medias de 20 y 50 sesiones, RSI, momento y volatilidad), arriesga como mucho el 1 % del patrimonio por operación, pone un stop de protección y lo sube cuando el precio sube, vende en el objetivo o si se rompe la tendencia, y aprende de sus operaciones cerradas. Su diario explica por qué compra, vende o espera, y la curva de patrimonio y los gráficos de cada orden se ven en vivo. Se ajusta (o se para) en la vista Bolsa o con `POST /api/bolsa/agente`. Con el perfil *Bolsa e inversiones* los agentes de la oficina también usan la mesa. Una cartera **real** solo sirve de seguimiento: ninguna orden se ejecuta sin que escribas `CONFIRMO`, y Nexus-Office no se conecta a ningún bróker. Ver BOLSA.md.

Modelos

En modo usuario verás los **recomendados para tu equipo** con una etiqueta: *ideal*, *compatible*, *pesado* o *no cabe*. Si el instalador no pudo descargar el modelo elegido (por ejemplo, sin internet), pulsa **Descargar** en el marcado con ★ y después **Activar**. Descarga también el modelo de **embeddings** (Qwen3-Embedding, 639 MB): mejora la búsqueda en tu biblioteca y en la memoria y se activa solo.

Ajustes

Nombre del asistente, idioma, estilo de respuesta (breve/equilibrado/detallado), agente por defecto, memoria, voz, velocidad de voz, avatar y color de acento.

En modo administrador aparece el **Gestor de conocimiento**: lo que Nexus-Office sabe de ti y es común a todos los agentes, lo que sabe cada agente de su especialidad, importar grafos y leer un ZIP. Ver MEMORIA.md.

Puedes **importar como conocimiento un grafo de cualquier formato** (Gephi, Cytoscape, Neo4j, RDF/OWL, Excel, Mermaid, mapas mentales, la base de otro Nexus-Office…): suéltalo en *Gestor de conocimiento > Importar / exportar*, pídeselo a un agente en el chat o usa `python -m nexus grafo importar fichero`. El formato se reconoce solo y lo importado se suma a lo que Nexus-Office ya sabe. Ver GRAFOS.md. Para probarlo, los paquetes traen en `ejemplos/grafo-wikipedia-es/` un **grafo multicapa de la Wikipedia en español** (temas, artículos, enlaces y hechos de Wikidata): `python -m nexus grafo importar ejemplos/grafo-wikipedia-es/grafo.graphml --en auto`.

En `ejemplos/resumen-proyecto/` está **Nexus-Office-resumen.md**, un resumen de todo el programa. Súbelo a la **Biblioteca** y los agentes sabrán responder preguntas sobre el propio Nexus-Office.

Nexus-Office recuerda las pautas que le pidas («no uses emojis», «respóndeme siempre con ejemplos», «llámame Joseba») y todos los agentes las respetan.

Profesor (IA online)

El agente **Profesor** enseña y resuelve dudas. Si un administrador pone en *Ajustes → Profesor* la clave de una IA online (Google Gemini, ChatGPT, Perplexity, Claude, Mistral, DeepSeek, Groq, OpenRouter u otra compatible con OpenAI), el Profesor la usa; si no, responde con el modelo local. Los demás agentes le preguntan cuando no saben algo y guardan la lección en su memoria. Ninguna otra parte de Nexus-Office usa la IA online, y la clave nunca se muestra. Desde la terminal: `curl -X PUT -H "X-Admin-Token: ..." -H "Content-Type: application/json" -d '{"proveedor":"gemini","clave":"..."}' http://127.0.0.1:8775/api/nube`.

Dispositivos: luces, reloj y Pico W

Nexus-Office reparte su estado (escuchando, pensando, hablando...) a las **luces NexusLED** (ESP32 con tiras WS2812/SK6812), al **reloj NexusWatch** (ESP32-2424S012C) y al **avatar de bolsillo NexusPico** (Pico W con pantalla de tinta). En *Dispositivos* buscas las luces de tu red, eliges efectos y brillo, y cambias de **modo** (Normal, Manos libres, Silencio, Concentración, Rendimiento, Ahorro, Noche) desde el ordenador, el móvil o el reloj. El reloj muestra qué hace cada agente. Desde *Dispositivos > Grabar firmware* (o con `python firmware/flash.py`) se graba el firmware por USB sin internet: los binarios y esptool vienen en la carpeta `firmware/` del paquete, y Nexus le pone la Wi-Fi y su dirección. Ver DISPOSITIVOS.md.

Motor y acelerador

Al abrir Nexus-Office puedes elegir el motor de IA y si usa la CPU, la GPU o la NPU, probarlo y ver dónde ha quedado el modelo de verdad. Después lo cambias cuando quieras en los menús **IA** y **PERFIL** de la barra superior. Ver ACELERADOR.md.

Leer páginas web como un navegador

Muchas webs se pintan con JavaScript y por debajo están vacías. Cuando la Biblioteca, *URL a PDF* o un agente leen una de ellas, Nexus-Office la abre con el Chrome, Edge o Chromium del equipo, sin ventana, y se queda con lo que verías tú. Usa un perfil propio que se limpia antes de cada lectura y solo llega a direcciones públicas. Se elige en el menú **MEMORIA**. Ver RAG.md.

Usarlo desde el móvil, tablet o consola

Nexus-Office tiene que escuchar en la red local: instala el arranque automático con *accesible desde la red local*, activa *Red COOP → Conectar dispositivos → Permitir acceso desde la red* o arráncalo con `--host 0.0.0.0`. Después abre `http://IP-DEL-PC:8775` desde el navegador del otro dispositivo e introduce la **clave de red** que aparece en *Conectar dispositivos*. Puedes **instalarlo como app** (PWA) desde el menú del navegador, o usar la **app Nexus-Office** (menú **RED → Conectar a mi ordenador**).

La interfaz se adapta sola al dispositivo:

- **Móvil:**
- Chat, Salón, Núcleo y Estudio están en la barra inferior. El resto de secciones está en **Más** (⋯).
- El avatar aparece en una franja sobre el chat. Se pliega con el botón de la persona y se recoge solo al abrir el teclado.
- Intro hace un salto de línea; para enviar, pulsa el botón de enviar.
- En horizontal, las secciones pasan a una barra lateral.
- **Tablet:** el avatar va arriba en vertical y a la derecha en horizontal.
- **Desde fuera de casa:** en la app Android, *Conectar desde internet* y pega el código que te dé el administrador. Más detalles en Acceso remoto.
- **App Android:**
- El botón **Atrás** cierra menús y diálogos y vuelve al chat antes de salir.
- Las barras del sistema toman el color del tema.
- **Cambiar de servidor** está en **Más**.
- **Móviles modestos:** se desactivan los efectos pesados para que todo vaya fluido.

Si prefieres otro diseño, cámbialo en *Ajustes → Diseño de la interfaz* (Automático, Móvil, Tablet o Escritorio). El cambio solo afecta a ese dispositivo.

Oficina para pymes: perfiles por gremio

Nexus-Office se puede instalar como **la oficina de una pyme**. Eliges el tipo de empresa (un *perfil*) y Nexus-Office monta su equipo de agentes:

- **Agentes de oficina**: Recepción, Administración, Presupuestos, Compras y almacén, Prevención de riesgos, Personal, Calidad y Comercial (cada perfil usa los que necesita).
- **Agentes del gremio**: Herrero, Calderero, Soldador, Albañil, Fontanero, Electricista, Carpintero, Pintor, Cerrajero, Climatización, Mecánico, Maestro panadero y Jardinero.
- **El coordinador** (el agente principal) pasa a llamarse como la oficina («Oficina Herrería»…), conoce a qué se dedica la empresa y reparte el trabajo con `delegate` entre su equipo.

Cada agente tiene su propio grafo

Cada agente, incluidos los del gremio, aprende en **su propio subgrafo aislado** (ver Memoria): el herrero no ve lo que sabe el calderero y al revés. Lo común (quién es el usuario, cómo quiere que le respondan, los clientes y relaciones) va al grafo general, que ven todos.

Al aplicar un perfil, el grafo de cada agente **nace sembrado** con su saber hacer básico (normas, reglas de cálculo, procedimientos: CTE DB-SUA para barandillas, desarrollo de virolas, REBT, RITE, RD 1457/1986…). A partir de ahí crece con sus conversaciones y con los documentos que importes solo para él (*Memoria → Biblioteca → importar para un agente*). Puedes ver cada grafo en el selector del grafo (*general*, *todos* o un agente).

Perfiles incluidos

La oficina de bolsa e inversiones trae además una mesa de bolsa simulada para practicar sin dinero: ver BOLSA.md.

59 perfiles: oficios y construcción, industria, comercio, hostelería, salud, servicios profesionales, bolsa e inversiones, educación y cuidados, agro, transporte y servicios técnicos. Los agentes de oficina (recepción, administración, presupuestos, compras, prevención, personal, calidad, comercial, agenda, protección de datos y medio ambiente) se comparten entre perfiles; los del sector traen el conocimiento y la normativa de cada actividad.

Perfil	Empresa	Agentes del sector	Agentes de oficina	Modelos sugeridos
`academia-formacion`	Academia y centro de formación	Coordinación académica	Recepción, Agenda y reservas, Administración, Comercial y marketing, Personal, Protección de datos	Qwen3.5 9B · alto rendimiento, Qwen3-Embedding 0.6B
`agencia-marketing`	Agencia de marketing	Estratega de marketing, Técnico informático	Presupuestos, Administración, Recepción, Agenda y reservas, Protección de datos	SDXL-Turbo, SD-Turbo
`agricultura`	Explotación agrícola	Técnico agrícola, Mecánico	Medio ambiente y residuos, Administración, Compras y almacén, Comercial y marketing, Prevención de riesgos	—
`arquitectura-ingenieria`	Estudio de arquitectura e ingeniería	Arquitecto e ingeniero	Presupuestos, Prevención de riesgos, Calidad, Administración, Recepción, Agenda y reservas, Protección de datos	Qwen3.5 9B · alto rendimiento, Qwen3-Embedding 0.6B
`asesoria-gestoria`	Asesoría y gestoría	Asesor fiscal y contable, Asesor laboral	Protección de datos, Recepción, Agenda y reservas, Administración, Comercial y marketing	Qwen3.5 9B · alto rendimiento, Qwen3-Embedding 0.6B
`autoescuela`	Autoescuela	Profesor de autoescuela	Recepción, Agenda y reservas, Administración, Comercial y marketing, Protección de datos	Qwen3.5 9B · alto rendimiento, Qwen3-Embedding 0.6B

Perfil	Empresa	Agentes del sector	Agentes de oficina	Modelos sugeridos
`ayuda-domicilio-residencia`	Ayuda a domicilio y residencia	Coordinación sociosanitaria	Personal, Prevención de riesgos, Calidad, Compras y almacén, Administración, Recepción, Protección de datos	MedGemma 4B, Qwen3-Embedding 0.6B
`bar-cafeteria`	Bar y cafetería	Jefe de sala, Jefe de cocina	Calidad, Compras y almacén, Administración, Personal, Comercial y marketing	—
`bodega-almazara`	Bodega y almazara	Enólogo y maestro de almazara, Técnico agrícola	Calidad, Medio ambiente y residuos, Comercial y marketing, Compras y almacén, Administración, Personal	—
`bolsa-inversiones`	Bolsa e inversiones	Analista de mercados, Gestor de carteras, Operador de mesa, Riesgos y cumplimiento, Fiscalidad de inversiones	Recepción, Agenda y reservas, Administración, Comercial y marketing, Protección de datos	Qwen3.5 9B · alto rendimiento, Qwen3-Embedding 0.6B
`caldereria`	Calderería industrial	Calderero, Soldador	Calidad, Presupuestos, Administración, Compras y almacén, Prevención de riesgos, Personal	—
`carniceria-charcuteria`	Carnicería y charcutería	Maestro carnicero, Encargado de tienda	Calidad, Compras y almacén, Administración, Comercial y marketing	—
`carpinteria`	Carpintería y ebanistería	Carpintero, Pintor	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	SDXL-Turbo, SD-Turbo
`carpinteria-aluminio-pvc`	Carpintería de aluminio y PVC	Técnico de carpintería de aluminio y PVC, Cristalero, Cerrajero	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`catering-eventos`	Catering y eventos	Organizador de eventos, Jefe de cocina, Jefe de sala	Presupuestos, Agenda y reservas, Calidad, Compras y almacén, Administración, Personal, Comercial y marketing	SDXL-Turbo, SD-Turbo
`centro-estetica`	Centro de estética	Esteticista	Agenda y reservas, Recepción, Compras y almacén, Administración, Comercial y marketing, Calidad	—
`cerrajeria`	Cerrajería y carpintería metálica	Cerrajero, Herrero, Soldador	Recepción, Presupuestos, Administración, Compras y almacén	—
`clinica-dental`	Clínica dental	Coordinación clínica dental	Recepción, Agenda y reservas, Administración, Compras y almacén, Calidad, Personal, Protección de datos	MedGemma 4B, Qwen3-Embedding 0.6B
`comercio-minorista`	Comercio minorista (tienda)	Encargado de tienda	Compras y almacén, Administración, Comercial y marketing, Recepción, Personal	—
`construccion`	Construcción y obra nueva	Albañil, Herrero, Electricista, Fontanero	Prevención de riesgos, Calidad, Presupuestos, Administración, Compras y almacén, Personal	—
`control-plagas`	Control de plagas	Técnico de control de plagas, Responsable de limpieza	Medio ambiente y residuos, Recepción, Presupuestos, Administración, Calidad, Prevención de riesgos	—

Perfil	Empresa	Agentes del sector	Agentes de oficina	Modelos sugeridos
`cristaleria`	Cristalería	Cristalero, Técnico de carpintería de aluminio y PVC	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`despacho-abogados`	Despacho de abogados	Apoyo jurídico	Protección de datos, Recepción, Agenda y reservas, Administración, Presupuestos	Qwen3.5 9B · alto rendimiento, Qwen3-Embedding 0.6B
`electricidad`	Instalaciones eléctricas	Electricista	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`escuela-infantil`	Escuela infantil	Coordinación pedagógica infantil	Recepción, Administración, Personal, Calidad, Compras y almacén, Protección de datos, Prevención de riesgos	—
`estructuras-metalicas`	Estructuras metálicas y montajes	Herrero, Calderero, Soldador	Calidad, Presupuestos, Administración, Compras y almacén, Prevención de riesgos, Personal	—
`estudio-fotografia`	Estudio de fotografía	Fotógrafo	Agenda y reservas, Presupuestos, Recepción, Administración, Comercial y marketing	SDXL-Turbo, SD-Turbo
`farmacia`	Farmacia	Gestión de farmacia, Encargado de tienda	Compras y almacén, Administración, Calidad, Personal, Comercial y marketing	MedGemma 4B, Qwen3-Embedding 0.6B
`fisioterapia`	Centro de fisioterapia	Coordinación de fisioterapia	Agenda y reservas, Recepción, Administración, Comercial y marketing, Protección de datos	MedGemma 4B, Qwen3-Embedding 0.6B
`floristeria`	Floristería	Florista	Agenda y reservas, Recepción, Compras y almacén, Presupuestos, Administración, Comercial y marketing	SDXL-Turbo, SD-Turbo
`fontaneria-climatizacion`	Fontanería y climatización	Fontanero, Climatización, Electricista	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`fruteria-alimentacion`	Frutería y alimentación	Frutero, Encargado de tienda	Calidad, Compras y almacén, Administración, Comercial y marketing	—
`ganaderia`	Explotación ganadera	Técnico ganadero, Técnico agrícola, Coordinación veterinaria	Medio ambiente y residuos, Administración, Compras y almacén, Calidad, Prevención de riesgos	—
`gestion-residuos`	Gestión de residuos	Jefe de tráfico, Mecánico	Medio ambiente y residuos, Recepción, Administración, Comercial y marketing, Calidad, Personal, Prevención de riesgos	—
`herreria`	Herrería y forja	Herrero, Soldador	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`hotel-alojamiento`	Hotel y alojamiento turístico	Jefe de alojamiento	Agenda y reservas, Recepción, Administración, Comercial y marketing, Personal, Compras y almacén, Calidad	—

Perfil	Empresa	Agentes del sector	Agentes de oficina	Modelos sugeridos
`imprenta-artes-graficas`	Imprenta y artes gráficas	Jefe de producción gráfica	Medio ambiente y residuos, Recepción, Presupuestos, Administración, Compras y almacén, Comercial y marketing, Calidad	SDXL-Turbo, SD-Turbo
`inmobiliaria`	Agencia inmobiliaria	Agente inmobiliario	Comercial y marketing, Recepción, Agenda y reservas, Administración, Protección de datos	Qwen3.5 9B · alto rendimiento, Qwen3-Embedding 0.6B
`instalaciones-solares`	Instalaciones solares	Instalador solar, Electricista, Climatización	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`jardineria`	Jardinería y paisajismo	Jardinero, Fontanero	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`lavanderia-tintoreria`	Lavandería y tintorería	Tintorero	Recepción, Compras y almacén, Administración, Prevención de riesgos, Comercial y marketing	—
`limpieza-profesional`	Limpieza profesional	Responsable de limpieza, Técnico de control de plagas	Recepción, Presupuestos, Administración, Compras y almacén, Personal, Calidad, Prevención de riesgos	—
`mantenimiento-integral`	Mantenimiento integral y multiservicios	Albañil, Fontanero, Electricista, Pintor, Cerrajero, Climatización	Recepción, Presupuestos, Administración, Prevención de riesgos, Personal	—
`marmoleria-piedra`	Marmolería y piedra	Marmolista, Albañil	Medio ambiente y residuos, Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`mudanzas`	Mudanzas y guardamuebles	Jefe de mudanzas, Jefe de tráfico, Carpintero	Recepción, Presupuestos, Administración, Personal, Prevención de riesgos	—
`optica`	Óptica	Óptico-optometrista, Encargado de tienda	Agenda y reservas, Compras y almacén, Administración, Comercial y marketing, Calidad	MedGemma 4B, Qwen3-Embedding 0.6B
`panaderia`	Panadería y obrador	Maestro panadero	Calidad, Compras y almacén, Administración, Personal, Comercial y marketing, Recepción	—
`peluqueria-barberia`	Peluquería y barbería	Peluquero estilista	Agenda y reservas, Recepción, Compras y almacén, Administración, Comercial y marketing, Personal	—
`pintura`	Pintura y decoración	Pintor, Albañil	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	SDXL-Turbo, SD-Turbo
`piscinas`	Piscinas	Técnico de piscinas, Fontanero, Electricista, Albañil	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`reformas`	Albañilería y reformas	Albañil, Fontanero, Electricista, Pintor	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—

Perfil	Empresa	Agentes del sector	Agentes de oficina	Modelos sugeridos
`restaurante`	Restaurante	Jefe de cocina, Jefe de sala	Agenda y reservas, Calidad, Compras y almacén, Administración, Personal, Comercial y marketing	—
`servicios-informaticos`	Servicios informáticos	Técnico informático	Protección de datos, Recepción, Agenda y reservas, Presupuestos, Compras y almacén, Administración	Qwen2.5-Coder 7B, Qwen3-Embedding 0.6B
`taller-mecanico`	Taller mecánico	Mecánico	Recepción, Compras y almacén, Presupuestos, Administración, Comercial y marketing, Prevención de riesgos	—
`tapiceria`	Tapicería	Tapicero, Carpintero, Jefe de taller de confección	Recepción, Presupuestos, Administración, Compras y almacén, Comercial y marketing	—
`telecomunicaciones`	Instalaciones de telecomunicaciones	Instalador de telecomunicaciones, Electricista	Recepción, Presupuestos, Administración, Compras y almacén, Prevención de riesgos	—
`textil-confeccion`	Textil y confección	Jefe de taller de confección, Tapicero	Medio ambiente y residuos, Calidad, Compras y almacén, Comercial y marketing, Presupuestos, Administración, Personal	SDXL-Turbo, SD-Turbo
`transporte-logistica`	Transporte y logística	Jefe de tráfico, Mecánico	Medio ambiente y residuos, Recepción, Administración, Comercial y marketing, Personal, Prevención de riesgos	—
`veterinaria`	Clínica veterinaria	Coordinación veterinaria	Agenda y reservas, Recepción, Compras y almacén, Administración, Comercial y marketing, Protección de datos	MedGemma 4B, Qwen3-Embedding 0.6B

Modelos de IA sugeridos para cada sector

Al instalar, Nexus-Office elige el modelo general según el hardware (`python -m nexus modelos`). Si además hay un modelo específico que encaja con la oficina, lo **sugiere** una vez instalada: aparece primero en **Modelos > Recomendados** con la etiqueta «◆ para tu oficina» y el motivo, y también al aplicar el perfil (`python -m nexus oficina <id>`) y en `python -m nexus modelos`. No se descarga solo: lo decides tú, viendo si cabe en tu equipo.

- **Salud** (clínica dental, fisioterapia, farmacia, óptica, veterinaria, ayuda a domicilio): MedGemma 4B, entrenado con textos e imágenes médicas. Es apoyo para el profesional colegiado, nunca un diagnóstico.
- **Servicios informáticos**: Qwen2.5-Coder 7B, especializado en programación, scripts y redes.
- **Despachos y documentación** (asesoría, abogados, inmobiliaria, arquitectura, academia, autoescuela): el modelo de razonamiento grande (Qwen3.5 9B, con visión) y el de documentos, para normativa y contratos largos.
- **Diseño e imagen** (marketing, imprenta, fotografía, floristería, pintura, carpintería, confección, eventos): el modelo de imagen de más calidad que permita el equipo.

Un perfil puede fijar los suyos con la clave `modelos: [{id: ..., motivo: ...}]` (ids de `nexus/models/recommended.py`).

Elegir un perfil

Desde la interfaz (modo administrador): *Agentes → Perfil de oficina*, elige la empresa y pulsa **APLICAR**.

Desde la terminal (Windows: `venv\python.exe`, Linux/macOS: `venv/bin/python3`):

```
python -m nexus oficina                     # lista los perfiles y marca el activo
python -m nexus oficina herreria            # aplica el perfil
python -m nexus oficina herreria --reset-agentes   # y reescribe también los agentes que hayas personalizado
python -m nexus oficina --quitar            # vuelve a los agentes por defecto de Nexus-Office
```

Al instalar: en el instalador de Windows, el desplegable *Perfil de oficina* de la página *Opciones* (o `/OFICINA=herreria` en modo silencioso); `sh Nexus-Office-2.2.0-linux-x86_64.run --oficina=herreria` (Linux y Raspberry Pi); `./install.sh --oficina=herreria` (macOS y código fuente); `install.bat -Oficina herreria` (Windows desde el código fuente); `bash install-termux.sh --oficina=herreria` (Android con Termux), o la variable de entorno `NEXUS_OFICINA=herreria` con los scripts. Con el `.deb`: `nexus-office oficina herreria`. Ver Instalación.

En Android: - **App Nexus-Office autónomo (APK)**: no tiene terminal; el perfil se elige en la propia app: *Más* → *Agentes*, botón **ADMIN** (PIN), *Perfil de oficina* → **APLICAR**. La APK lleva dentro todo `nexus/`, también los perfiles y agentes de la oficina, y cada agente estrena su grafo en el móvil. - **Termux**: igual que en Linux (`venv/bin/python -m nexus oficina herreria`) o desde el navegador del móvil. - **App Nexus-Office VPN** (cliente del PC): usa la oficina que tenga configurada el PC.

Por API: `GET /api/office/profiles` y `POST /api/office/profile {"id": "herreria"}` (administrador; `{"id": ""}` quita el perfil).

Aplicar un perfil **no borra nada**: los agentes que no forman parte de la oficina se desactivan y conservan su memoria; si un agente ya existía y lo habías personalizado se respeta (salvo con `--reset-agentes`); antes de sobrescribir un YAML se guarda una copia en `data/agents/respaldo/`. El perfil activo queda en `data/config.yaml` (`office.profile`).

Sin internet

Los perfiles son YAML y el conocimiento sembrado va a la base SQLite local: todo funciona **100 % offline** en Windows, macOS, Linux y Android (app autónoma y Termux). Los agentes de la oficina no usan herramientas que necesiten internet (búsqueda web, descarga de páginas, rastreo); solo hace falta red para descargar los modelos de IA (o tráelos ya descargados, ver Plataformas). Si quieres que un agente busque en internet, añádele `web_search` en *Agentes → Editar*.

Crear o ampliar perfiles

- **Agentes**: `nexus/office/agentes/<id>.yaml`. Mismo formato que los agentes de Nexus-Office (`name`, `description`, `system_prompt`, `tools`, `keywords`, `specialty`, `can_delegate_to`…) más la clave `grafo`: tripletas `"sujeto | relación | objeto"` con una cuarta parte opcional para la categoría (`especialidad`, `procedimiento`, `documento`, `experiencia`).
- **Perfiles**: `nexus/office/perfiles/<id>.yaml` con `name`, `sector`, `assistant_name`, `icon`, `description`, `agents` (ids del catálogo) y `coordinator.context` (a qué se dedica la empresa).

Los agentes de oficina son los de `OFFICE_ROLES` en `nexus/office/__init__.py`; el resto cuenta como gremio. `tests/test_office.py` comprueba que todo perfil es coherente, que cada agente tiene su grafo y que el enrutado lleva cada consulta al agente de su gremio.

Paquetes de conocimiento

Un paquete (`nexus/office/conocimiento/<id>/`) lleva un manual en Markdown para la biblioteca RAG y un `grafo.yaml` con tripletas, y dice en `paquete.yaml` qué agentes lo reciben y qué herramientas les añade. Al arrancar (y al aplicar un perfil desde la app) se instala en la biblioteca y el subgrafo **propios** de cada agente activo de la lista, nunca en el grafo general. El primero es el manual de GIMP para los agentes de imagen y diseño: ver GIMP.md. Se desactivan con `office.knowledge_packs: false`.

Oficina de bolsa e inversiones y mesa simulada

El perfil `bolsa-inversiones` convierte Nexus-Office en la oficina de una pyme o un despacho que trabaja con bolsa, fondos, ETF, renta fija y criptoactivos. Trae una **mesa de bolsa simulada** para practicar sin dinero en un entorno que imita uno real, en Windows, macOS, Linux, Raspberry Pi y Android. Desde la 2.1 la mesa usa **cotizaciones reales** cuando hay conexión, y sin ella sigue simulada desde el último precio real.

> **Aviso.** La mesa es **siempre simulada**: nunca usa dinero ni envía órdenes a ningún bróker. Con conexión los precios son reales (con el retraso de cada bolsa); sin ella, simulados. Nada de lo que dicen los agentes es asesoramiento financiero personalizado, que solo puede dar una entidad o un asesor registrado en la CNMV. Invertir conlleva el riesgo de perder dinero.

Datos reales (2.1)

Con `bolsa.datos: "reales"` (por defecto) la mesa toma las cotizaciones y el cambio de divisa de internet:

Fuente	Para qué	Retraso
Yahoo Finance	Acciones, ETF, cripto y divisas con los mismos símbolos del catálogo (SAN.MC, AAPL, VWCE.DE, BTC-EUR, EURUSD=X) y gráficos	≈15 min en bolsa, tiempo real en cripto
CNBC	Respaldo de cotizaciones y **velas** de acciones cuando Yahoo limita (pasa mucho desde servidores)	≈15 min
Google Finance y **Stooq**	Respaldo de cotizaciones	≈15 min
Coinbase y **Kraken**	Respaldo de cotizaciones y **velas** de cripto	Tiempo real
BCE	Cambio de divisa de respaldo	Diario

Cada fuente que falla se aparta un rato (30 s, 60 s, 120 s… hasta 15 min) y se prueba la siguiente. Sin ninguna, la mesa sigue con la simulación desde el último precio real. Cada precio dice su fuente y su retraso. `bolsa.datos: "simulados"` vuelve a los precios ficticios de antes.

Agente de bolsa autónomo (2.1)

Gestiona su propia cartera **simulada** («Agente autónomo (simulada)») con esos datos reales, como lo haría una persona en la mesa, con sus comisiones, horquilla y horarios. En cada ciclo (60 s por defecto):

1. Recopila cotizaciones y cierres diarios de su universo de valores y guarda el histórico para trabajar sin red.
2. Calcula medias de 20 y 50 sesiones, RSI de 14, momento ajustado por volatilidad y ATR.
3. Puntúa cada valor con pesos que **aprende** de sus operaciones cerradas.
4. Gestiona lo que tiene: stop de protección en el libro, stop que sube con el precio, toma de beneficios y salida si se rompe la tendencia.
5. Abre posiciones con la bolsa abierta arriesgando como mucho el 1 % del patrimonio por operación (stop a 2 ATR), con límites de peso por valor, de posiciones y una reserva de liquidez.

Su **diario** explica por qué compra, vende o espera. En la vista Bolsa se ven en vivo su curva de patrimonio y el **gráfico de cada orden activa** (precio, límite, stop, ejecución y objetivo). Se ajusta o se para en la vista Bolsa o con `POST /api/bolsa/agente` (`activo`, `intervalo_s`, `riesgo_pct`, `max_posiciones`, `max_peso_pct`, `reserva_pct`, `universo`, `capital`); `GET /api/bolsa/agente` da su estado. Nunca opera con dinero real.

Agentes

Agente	Qué hace	Herramientas de la mesa
Analista de mercados (`analista-mercados`)	Análisis fundamental (PER, BPA, EV/EBITDA, deuda, flujo de caja, dividendos) y técnico (medias, RSI, MACD), renta fija y criptoactivos	`bolsa_cotizacion`, `bolsa_mercados`
Gestor de carteras (`gestor-carteras`)	Asignación de activos, diversificación, rebalanceo, aportaciones periódicas, gastos, traspasos de fondos	`bolsa_cartera`, `bolsa_costes`, `bolsa_cotizacion`

Agente	Qué hace	Herramientas de la mesa
Operador de mesa (`operador-bolsa`)	Da y vigila las órdenes, explica tipos de orden, horarios, comisiones y liquidación	todas menos el informe fiscal
Riesgos y cumplimiento (`riesgos-inversion`)	Tamaño de posición, stops, volatilidad, caídas máximas, MiFID II, KID, CNMV, chiringuitos, MiCA	`bolsa_cartera`, `bolsa_cotizacion`, `bolsa_costes`
Fiscalidad de inversiones (`fiscalidad-inversiones`)	IRPF de ganancias y pérdidas, FIFO, regla de los dos meses, dividendos, modelos 720 y 721	`bolsa_informe_fiscal`, `bolsa_cartera`

Además lleva los agentes de oficina comunes: recepción, agenda, administración, comercial y protección de datos. Cada agente aprende en su propio grafo, como en el resto de perfiles (ver OFICINA.md).

```
python -m nexus oficina bolsa-inversiones
```

La mesa simulada

Se abre en la sección **BOLSA** de la app (en el móvil, en *Más*) o con `python -m nexus bolsa`. Los datos se guardan en `data/bolsa/bolsa.db`.

- **Cartera ficticia** en euros, con 10.000 € de partida (puedes crear otras con el capital y la tarifa que quieras, y reiniciarlas).
- **Valores de varias bolsas**: acciones de BME, Xetra, Euronext, Londres, NYSE y Nasdaq, ETF de renta variable y de bonos, y bitcoin y ether. Puedes añadir cualquier otro con su precio de referencia.
- **Precios que se mueven como en el mercado**: mientras la bolsa está abierta el precio sigue un paseo aleatorio con la volatilidad de cada activo, en cada apertura hay un pequeño salto y con la bolsa cerrada el precio no se mueve. Si pegas cierres reales (`fecha;cierre`, o un CSV con columnas *Date* y *Close*), el valor se ancla al último cierre y usa la volatilidad de esos datos.
- **Horarios reales**: cada bolsa en su hora local, con el cambio de hora de verano de Europa y de EE. UU. y sus festivos (Viernes Santo, Lunes de Pascua, 1 de mayo, Nochebuena, Navidad, San Esteban y Nochevieja en Europa; los de la NYSE en EE. UU.). Las criptomonedas cotizan 24 horas todos los días.
- **Órdenes** a mercado, limitadas, stop y stop limitadas, válidas el día o hasta cancelar (90 días). Con la bolsa cerrada la orden espera a la apertura. El efectivo de las compras abiertas queda reservado. No hay ventas en corto.
- **Ejecución realista**: se compra al precio de venta y se vende al de compra (horquilla), con **deslizamiento** que crece con el tamaño de la orden frente al volumen diario del valor.
- **Costes**: tres tarifas típicas (bróker online, banco tradicional, neobróker) con comisión nacional, internacional y de cripto; canon aproximado de BME; impuesto sobre transacciones financieras (0,2 % en compras de grandes empresas españolas, 0,3 % en francesas); y coste del cambio de divisa en valores en dólares o libras.
- **Resultado como en Hacienda**: posiciones por lotes **FIFO**, ganancia o pérdida realizada en euros con gastos incluidos, informe fiscal anual por valor y aviso de la **regla de los dos meses** (art. 33.5 LIRPF) cuando vendes con pérdidas y conservas o recompras títulos del mismo valor.

Las órdenes pendientes se revisan cada vez que se consulta la mesa (la app, la terminal o un agente). Las cifras de tarifas, canon e impuestos son aproximadas y se pueden ajustar en `nexus/office/bolsa.py` (`TARIFAS`, `CANON_BME` y la columna `impuesto_pct` de cada valor).

Cartera real: nunca sin tu confirmación

Una cartera en modo **real** sirve para llevar el seguimiento de tus inversiones de verdad, y está pensada para que nada se ejecute por su cuenta:

1. Cualquier orden (tuya o de un agente) queda **por confirmar**. No se envía a ningún sitio.
2. Solo una persona puede confirmarla, escribiendo `CONFIRMO`: en la app con el modo **ADMIN** activo, o en la terminal con `python -m nexus bolsa confirmar <id>`. Ningún agente tiene una herramienta para confirmar.
3. **Nexus-Office no se conecta a ningún bróker.** La orden confirmada la ejecutas tú en tu bróker.
4. Después registras la ejecución real (precio, comisiones) con *REGISTRAR EJECUCIÓN* o `python -m nexus bolsa ejecucion <id> <precio> --comision <euros>`, y la cartera se actualiza.

Crear una cartera real también requiere el modo administrador.

Terminal

```
python -m nexus bolsa                          # resumen de la cartera
python -m nexus bolsa mercados                 # bolsas abiertas o cerradas, en hora local
python -m nexus bolsa valores santander        # buscar valores
python -m nexus bolsa cotizar SAN.MC
python -m nexus bolsa comprar SAN.MC 100
python -m nexus bolsa comprar AAPL 5 --tipo limitada --limite 210 --validez hasta_cancelar
python -m nexus bolsa vender SAN.MC 50 --tipo stop --stop 5.6
python -m nexus bolsa ordenes | operaciones | cancelar <id>
python -m nexus bolsa nueva "Reto 2027" --capital 3000 --tarifa neobroker
python -m nexus bolsa reiniciar --cartera 2
python -m nexus bolsa importar SAN.MC cierres.csv
python -m nexus bolsa fiscal 2026
python -m nexus bolsa nueva "Mi cartera" --modo real --capital 12000     # seguimiento, sin ejecutar nada
python -m nexus bolsa confirmar <id>
python -m nexus bolsa ejecucion <id> 6.12 --comision 8
```

En la app Nexus-Office autónomo de Android la mesa está en la sección **BOLSA** igual que en el escritorio.

API

Método y ruta	Uso
`GET /api/bolsa?cartera=<id>`	Resumen, mercados, carteras, órdenes y operaciones
`GET /api/bolsa/instrumentos?q=`	Buscar valores
`GET /api/bolsa/cotizacion/<símbolo>`	Cotización simulada y últimos precios
`POST /api/bolsa/costes`	Gastos estimados de una orden
`POST /api/bolsa/orden`	Nueva orden (`simbolo`, `lado`, `cantidad`, `tipo`, `limite`, `stop`, `validez`, `cartera`)
`POST /api/bolsa/orden/<id>/cancelar`	Cancelar
`POST /api/bolsa/orden/<id>/confirmar`	Confirmar una orden real (`{"confirmacion": "CONFIRMO"}`, requiere admin)
`POST /api/bolsa/orden/<id>/ejecucion`	Registrar la ejecución real (requiere admin)
`POST /api/bolsa/cartera`	Crear cartera (la real requiere admin)
`POST /api/bolsa/cartera/<id>/reiniciar`	Reiniciar una cartera simulada
`POST /api/bolsa/instrumento`	Añadir un valor propio
`POST /api/bolsa/importar`	Importar cierres reales (`simbolo`, `csv`)
`GET /api/bolsa/fiscal?anio=`	Ganancias y pérdidas realizadas del año

Nexus-Office como servicio: arranque automático

Instalado como **servicio**, Nexus-Office arranca solo al encender el equipo, sin ventana, y se reinicia si falla. Es lo normal en el PC de la oficina: los móviles y los otros equipos lo encuentran siempre en marcha, aunque nadie haya abierto la aplicación.

- Funciona en Windows, Linux (también Raspberry Pi), macOS, Android con Termux y la app **Nexus-Office autónomo**.
- El servicio apunta a la carpeta donde está instalado Nexus-Office. La carpeta sigue siendo portable, pero si la mueves, vuelve a instalar el servicio.
- Con el servicio en marcha, el acceso directo, `start.bat` o `./start.sh` **no arrancan un segundo Nexus-Office**: ven que ya responde y solo abren el navegador en `http://127.0.0.1:8775`.

Cómo se activa

Desde	Cómo
Instalador de Windows (`.exe`)	Página *Opciones* → **Arrancar Nexus-Office como servicio al encender el equipo** y, si quieres, **Accesible desde la red local**. Solo ese paso pide permiso de administrador (UAC). Silencioso: `/S /SERVICIO /RED`.
Instalador de Linux (`.run`) o `install.sh`	`--servicio`, y `--red` para la red local. Crea un servicio de usuario. Ejecuta el `.run` sin `sudo` (con `sudo` se instalaría en la carpeta de root) y, si quieres el servicio del sistema, después `sudo <carpeta>/venv/bin/python3 -m nexus servicio instalar`.
Paquete `.deb`	`sudo nexus-office servicio instalar [--red]`
macOS	`./install.sh --servicio [--red]`, o el comando de la terminal (abajo).
`install.ps1` / `install.bat`	`-Servicio`, y `-Red` para la red local.
Termux	`bash install-termux.sh --servicio` (siempre accesible desde la red local).
Interfaz web	*Sistema → Arranque automático* → **INSTALAR SERVICIO** (modo administrador). Marca *accesible desde la red local* si lo vas a usar desde móviles u otros PC.
App Nexus-Office autónomo	*Sistema → Arranque automático* → **ARRANCAR AL ENCENDER**.

También con la variable de entorno `NEXUS_SERVICIO=1` en `install.sh` e `install.ps1`.

Comandos

En Windows, `venv\python.exe`; en Linux y macOS, `venv/bin/python3`; con el `.deb`, `nexus-office` en lugar de `python -m nexus`.

```
python -m nexus servicio instalar             # arranque automático, escuchando solo en este equipo
python -m nexus servicio instalar --red       # escucha en la red local (0.0.0.0): móviles y otros PC
python -m nexus servicio instalar --puerto 9000
python -m nexus servicio estado               # tipo, dónde está registrado y si responde
python -m nexus servicio quitar               # lo quita (Nexus-Office sigue instalado)
```

Sin `--red` se usa la dirección de `server.host` de `data/config.yaml` (por defecto `127.0.0.1`), y sin `--puerto`, `server.port` (8775). `--host <ip>` fija otra dirección de escucha.

Desde la red, los dispositivos que no son el propio equipo necesitan la **clave de red** (*Red COOP → Conectar dispositivos*). Ver Acceso desde otros dispositivos.

Qué hace en cada sistema

Sistema	Con permisos de administrador	Sin permisos
Windows	Tarea programada «Nexus-Office» que arranca **con el equipo** (30 s después), con la cuenta SYSTEM. Con `--red`, abre el puerto en el Firewall de Windows (regla «Nexus-Office»).	Tarea programada que arranca **al iniciar sesión** tu usuario. Sin regla de firewall: con `--red`, Windows puede preguntar la primera vez si permite el acceso.

Sistema	Con permisos de administrador	Sin permisos
Linux con systemd	Servicio del sistema `/etc/systemd/system/nexus-office.service`, que corre como el usuario dueño de la carpeta (o el que hizo `sudo`). Arranca con el equipo.	Servicio de usuario `~/.config/systemd/user/nexus-office.service` y `loginctl enable-linger`, para que arranque al encender sin iniciar sesión. Si *linger* no se puede activar, arranca al iniciar sesión.
Linux sin systemd	Línea `@reboot` en el crontab.	Igual.
macOS	LaunchDaemon `/Library/LaunchDaemons/ai.nexus.office.server.plist`: arranca con el equipo.	LaunchAgent `~/Library/LaunchAgents/ai.nexus.office.server.plist`: arranca al iniciar sesión.
Android (Termux)	—	`termux-services` (`$PREFIX/var/service/nexus-office`) y, con la app **Termux:Boot**, arranque al encender el móvil (`~/.termux/boot/nexus-office.sh`, con *wake lock*).
App Nexus-Office autónomo	—	El servicio en primer plano de la app se lanza al encender el móvil y tras actualizar la app.

En todos los casos:

- Se reinicia solo si se cae: systemd a los 5 s, launchd a los 10 s, el Programador de tareas cada minuto (hasta 999 veces).
- No tiene límite de tiempo: en Windows la tarea no se para a las 72 h ni al pasar a batería.
- Arranca con `python -m nexus run --no-browser`, sin abrir el navegador.
- En Windows usa `pythonw.exe`, así que no abre ninguna ventana.

Para que el arranque sea **con el equipo** y no al iniciar sesión, instálalo con permisos de administrador: desde el instalador de Windows (pide UAC), con `sudo` en Linux y macOS, o desde una consola de administrador en Windows. Si lo instalas desde la interfaz web, se instala con los permisos de Nexus-Office (normalmente, los de tu usuario).

Con el `.deb`, `sudo nexus-office servicio instalar` crea el servicio del sistema, que corre como tu usuario y usa tus datos de `~/.local/share/nexus-office`.

App Nexus-Office autónomo (Android)

En *Sistema → Arranque automático*, pulsa **ARRANCAR AL ENCENDER**. Desde entonces, al encender el móvil (después del primer desbloqueo) se inicia el servicio en primer plano de Nexus-Office, con su notificación, sin abrir la app. **DESACTIVAR** lo deja como antes: Nexus-Office arranca al abrir la app.

Algunos fabricantes bloquean el arranque de las apps con el ahorro de batería extremo. Si no arranca solo, quita a Nexus-Office del ahorro de batería en los ajustes de Android. Si el sistema lo impide, Nexus-Office arranca igualmente al abrir la app.

Quitar el servicio

- **Interfaz web**: *Sistema → Arranque automático* → **QUITAR** (modo administrador).
- **Terminal**: `python -m nexus servicio quitar`. Si lo instalaste con permisos de administrador, quítalo también con ellos: `sudo` en Linux y macOS (`sudo nexus-office servicio quitar` con el `.deb`), o una consola de administrador en Windows.
- **Desinstalar**: el desinstalador de Windows y la desinstalación del `.deb` (`sudo apt remove nexus-office`) quitan el servicio antes de borrar Nexus-Office. En Windows, si la tarea era del sistema, pide permiso de administrador.
- **App Nexus-Office autónomo**: **DESACTIVAR** en *Sistema → Arranque automático*.

Quitar el servicio no borra nada: Nexus-Office sigue instalado con sus datos y se abre como siempre.

Registro (logs)

Sistema	Dónde
Windows	`data\logs\servicio.log` (con `pythonw.exe` no hay consola: la salida va a ese fichero, también al abrir Nexus-Office desde el acceso directo).
macOS	`data/logs/servicio.log`

Sistema	Dónde
Linux con systemd	`journalctl -u nexus-office` (del sistema) o `journalctl --user -u nexus-office` (de usuario).
Linux con cron	`data/logs/servicio.log`
Termux	`data/logs/current` (svlogd)

Con el `.deb`, `data/` es `~/.local/share/nexus-office`. El registro general de Nexus-Office (`data/logs/`) se ve también en *Sistema → Registro* (modo administrador).

Problemas frecuentes

- **`servicio estado` dice «en marcha: no»**: mira el registro. Si Nexus-Office se acaba de instalar, el primer arranque tarda más; en Windows, además, la tarea del sistema espera 30 s tras encender.
- **Solo arranca al iniciar sesión**: se instaló sin permisos de administrador. Quítalo y vuelve a instalarlo con `sudo` (Linux, macOS) o desde una consola de administrador (Windows). En Linux, el aviso de `loginctl enable-linger` indica lo mismo.
- **«el servicio del sistema se quita con sudo»** o **«no se pudo borrar la tarea»**: el servicio se instaló con permisos de administrador; quítalo con ellos.
- **Los móviles no conectan**: instálalo con `--red` (o marca *accesible desde la red local*), comprueba que usan la clave de red y, en Windows sin permisos de administrador, permite Nexus-Office en el firewall.
- **El puerto 8775 está ocupado**: otro programa (o un Nexus-Office abierto a mano antes de instalar el servicio) lo usa. Cierra Nexus-Office desde *Sistema → Apagar Nexus-Office* o instala el servicio con `--puerto`.
- **Has movido la carpeta**: el servicio sigue apuntando a la ruta antigua. `servicio quitar` y `servicio instalar` desde la carpeta nueva.
- **Linux sin systemd ni cron** (algunos contenedores): no hay servicio posible; arranca Nexus-Office con `./start.sh --no-browser`.
- **Termux dice que falta termux-services**: `pkg install termux-services`, reinicia Termux y `sv-enable nexus-office`. Para arrancar al encender el móvil, instala también la app Termux:Boot desde F-Droid y ábrela una vez.
- **Parar Nexus-Office sin quitar el servicio**: *Sistema → Apagar Nexus-Office* lo para hasta el siguiente arranque. Con el servicio de Windows o de Linux, si se cierra con error se vuelve a lanzar solo.

Avatares

Se eligen en **Ajustes → Avatar** (modo usuario). Todos reaccionan al estado (en línea, pensando, herramienta, hablando, escuchando), al volumen de la voz y muestran los nodos del grafo de memoria orbitando como partículas.

Avatar	Descripción	Coste
Geisha del eclipse (por defecto)	Construida a partir de la **hoja de personaje** (planos A–H): cada plano se segmenta del fondo, las siluetas de frente y perfil definen un **casco visual 3D** (anillos de anchura y profundidad por altura) y un shader proyecta las fotos de frente, perfiles y espalda mezclándolas según la orientación de la superficie. Cabeza articulada sobre cuerpo entero (kimono, obi, manos, sandalias), varillas *kanzashi* 3D, párpados y boca animados, fondo de pagoda y eclipse con corona del color del estado. **Doble clic** alterna busto / cuerpo entero. Si faltan los recursos, se usa la versión procedural anterior.	WebGL; fluido en gráficas integradas
Grafo neuronal	El avatar *es* la memoria: núcleo luminoso y entidades aprendidas en una esfera 3D en canvas 2D.	Mínimo
Modelo propio	Sube un **GLB, GLTF (embebido) o VRM**. Se escala y encuadra solo, reproduce su animación (prefiere una llamada *idle*), mueve la cabeza hacia el puntero si tiene hueso `head` y abre la boca con morphs `aa`, `mouthOpen`, `jawOpen`, `viseme_aa`…	Depende del modelo

Encuadre automático (2.0)

Todos los avatares 3D se encuadran solos en el hueco libre del panel, entre los rótulos, al cambiar el tamaño de la ventana, al girar el móvil o al cargar un modelo: - **Busto** (cabeza y hombros) o **cuerpo entero**: doble clic alterna entre los dos. - Los modelos propios en cualquier unidad (cm, mm, m) se normalizan a 1,75 m de alto; los tumbados o no humanos, por su lado mayor. Los VRM 0.x se giran para mirar a la cámara. - Si el modelo no tiene hueso `head`, el busto toma el 18 % superior. - La respiración ya no saca del encuadre a los modelos cuyo origen no está en los pies, y el aro de estado y las partículas se ajustan a la medida del modelo.

Encuadre en el chat (2.2)

Los modelos muy grandes, muy pequeños o con el origen lejos del cuerpo ya no se salen del hueco del chat: la cámara se coloca con la caja real del modelo ya escalado (no con la del fichero), en el hueco que deja libre el chat en ordenador, tableta y móvil, y vuelve a encuadrar cuando cambia el tamaño del panel.

Biblioteca de avatares 3D gratuitos (2.2)

En **Ajustes → Avatar → AVATARES 3D GRATIS** se buscan y descargan modelos gratuitos:

Fuente	Qué hay	Licencia
Open Source Avatars (opensourceavatars.com)	Cientos de avatares VRM: 100Avatars de Polygonal Mind, ToxSam, chibis… El índice está en GitHub y los modelos en Arweave o IPFS (si una pasarela falla prueba otra).	Casi todos CC0
Modelos de referencia	Muestras del VRM Consortium, Khronos glTF y three.js.	Abiertas
Sketchfab	Búsqueda de modelos descargables con licencia Creative Commons. Para descargar hace falta la clave de API gratuita de tu cuenta (*Ajustes → Avatar*, campo *Clave de API de Sketchfab*, `avatares.sketchfab_token`).	CC (la de cada modelo)

Lo descargado queda en `outputs/avatars` con su miniatura, autor, licencia y origen (`biblioteca.json`), y se elige como avatar en cualquier momento, también sin conexión. Solo se descargan direcciones que vienen del propio catálogo, de 300 MB como mucho y en GLB, GLTF o VRM.

API: `GET /api/avatares/buscar?fuente=osa|muestras|sketchfab&q=...`, `POST /api/avatares/descargar {id}` (devuelve un trabajo que se sigue en `GET /api/avatares/trabajo/{tid}`), `GET /api/avatares` (biblioteca), `POST /api/avatares/{id}/usar` y `DELETE /api/avatares/{id}`.

Crear un avatar de calidad a partir de imágenes

La geisha actual se genera a partir de la hoja de personaje (proyección de fotos sobre un volumen de siluetas): de frente y en perfil es fiel a la referencia, y en ángulos intermedios mezcla vistas. Para un modelo con malla y rig completos:

1. **Modelo propio GLB/VRM** creado en VRoid Studio o Blender, o generado con herramientas *image-to-3D* (Hunyuan3D, TripoSR, Meshy…) a partir de las imágenes de referencia, y después riggeado (Mixamo/AccuRIG) y con *blendshapes* de boca y parpadeo. Nexus-Office lo carga directamente.
2. **Mejorar la hoja**: planos de mayor resolución (≥1024 px por vista), fondo liso y vistas exactas de frente/perfil/espalda mejoran directamente el resultado de `geisha_assets.py`.

Imágenes de referencia necesarias

Del **mismo personaje**, coherentes entre sí (una *character sheet / turnaround*), PNG o JPG ≥ 1024 px, iluminación plana sin sombras duras, fondo liso:

#	Imagen	Para qué
1	**Rostro frontal** neutro: mirando a cámara, boca cerrada, ojos abiertos, sin inclinación, sin pelo cubriendo la cara	Textura de la cara y proporciones
2	**Perfil izquierdo y derecho** (90°) de la cabeza	Forma del cráneo, nariz, mentón y volumen del peinado
3	**Vista 3/4** de la cabeza	Validar volúmenes
4	**Peinado desde atrás y desde arriba** + primer plano de los *kanzashi* (horquillas, peineta, flores, cadenas de cuentas)	Modelado del moño y adornos
5	**Primeros planos del maquillaje**: ojos y boca	Detalle de la textura facial
6	**Estampado del kimono en plano** (tela extendida, sin pliegues) + **obi** y **collar**	Texturas de tela
7	**Tatuajes** de cuello, pecho, brazos y manos vistos de frente	Textura de piel
8	**Cuerpo entero** en pose T o A, de frente y de lado (si se quiere más que el busto)	Proporciones y rig
9	Opcional: **expresiones** (boca en «A», «O», «I», ojos cerrados, sonrisa)	*Blendshapes* de habla y parpadeo
10	Opcional: **fondo** por separado (pagoda, eclipse)	Escenario

Si las imágenes se generan con IA, pide una *"character turnaround sheet, front view, side view, back view, neutral expression, flat lighting, white background"* con el mismo personaje/semilla.

Regenerar el avatar con otra hoja de personaje

```
venv/python.exe packaging/geisha_assets.py ruta/a/la_hoja.jpg
```

Recorta los planos (coordenadas en `SHEET_BOXES`), segmenta, mide las siluetas y escribe `nexus/web/assets/geisha/` (PNG con transparencia + `rig.json`). Las referencias de alineación (coronilla, barbilla, cuello, suelo) están en `HEAD` y `BODY` al principio del script.

Salón virtual de agentes

El salón es a la vez una **visualización** (los agentes sentados alrededor de una mesa holográfica, con burbujas de diálogo y haces de luz cuando delegan) y un **mecanismo de aprendizaje colectivo**.

Despachos (2.2)

La pestaña **DESPACHOS**, junto a **SALÓN**, muestra un despacho por agente (una, dos o tres columnas según la pantalla) con una escena animada de lo que hace **de verdad** en ese momento. La actividad llega del servidor (`GET /api/agentes/actividad` y el evento `agent_activity` del WebSocket):

Actividad	Escena
Pensando	Mano en la barbilla, sorbos de café y bocadillo de pensamiento
Escribiendo, programando, calculando	Teclea; la pantalla de la pared muestra texto, código o cifras
Buscando en internet, leyendo	Navega o pasa páginas de un documento
Dibujando o editando imágenes	Lápiz sobre la tableta gráfica
Componiendo música	Cascos puestos y notas que salen
Preguntando al Profesor (IA online)	Habla por teléfono
Delegando	Pasa la tarea al compañero
En reunión	Sale por la puerta; cartel *EN EL SALÓN*
Sin tarea	Se levanta a la cafetera y vuelve

La ventana de cada despacho sigue la **hora real** (día, atardecer, noche) y la barra de abajo dice qué hace y en qué tarea. La pestaña elegida se recuerda en ese dispositivo.

Personajes: mujer u hombre (2.2)

Cada personaje del salón y de los despachos, **también el tuyo**, puede ser mujer u hombre. Cambia el peinado, la complexión, la barba (solo hombre), las pestañas y pendientes (solo mujer) y los labios.

- Agentes: *Agentes → editar → Sexo*, o el campo `sexo: mujer|hombre` del YAML. De serie: Nexus, Artista y Profesor son mujeres; Investigador, Programador y Forjador, hombres. Vacío = se elige por el nombre.
- Tú: *Ajustes → Tu personaje* (`user.sexo`).

Qué se registra

- **Informes de tarea**: cada petición resuelta deja en el salón el agente, los temas y las herramientas usadas (y si fallaron).
- **Delegaciones**: cuando un agente encarga una subtarea a otro, aparece un haz animado entre ambos.
- **Retroalimentación**: tus 👍/👎 suman o restan puntos al agente en esos temas.

Directorio de habilidades

Con esos datos se construye una matriz *agente × tema* (éxitos suavizados por Laplace). Se usa para: 1. **Enrutado automático**: `palabras clave + 0,8 × habilidad aprendida`. 2. **Delegación**: el prompt de cada agente incluye “Lo aprendido en el salón sobre tus compañeros”.

Reuniones

Se convocan manualmente (con tema opcional) o automáticamente cada `lounge.meet_every_tasks` tareas (8 por defecto): 1. Presentaciones (con LLM, cada agente habla en personaje; sin él, a partir de sus datos). 2. Repaso de tareas recientes: si otro agente tenía mejor encaje, lo dice (“puedes delegarme esto”). 3. **Detección de carencias**: temas que se repiten sin especialista o con resultados flojos. 4. **Propuesta de nuevo agente** (nombre, descripción, prompt, palabras clave, herramientas). Queda **pendiente de aprobación** de un administrador; al aprobarse, el agente se presenta en el salón y el enrutado empieza a usarlo.

Puedes hablar en el salón: responde el agente con mejor encaje para lo que digas.

Motor de IA y acelerador (CPU, GPU o NPU)

Desde la versión 2.0, al arrancar Nexus-Office puedes elegir a mano **con qué motor** se ejecuta el modelo de IA y **en qué chip**: el procesador (CPU), la tarjeta gráfica (GPU) o la unidad de IA (NPU). Si no eliges nada, lo decide Nexus-Office según tu equipo, como hasta ahora.

Dónde se elige

- **Al arrancar** aparece la ventana **MOTOR Y ACELERADOR**. Muestra tu procesador, memoria, GPU y NPU detectadas, y qué opciones están disponibles en este equipo (las que no, dicen por qué).
- **PROBAR** genera unas palabras con la opción marcada y dice cuánto ha tardado, los tokens por segundo y **dónde ha quedado el modelo de verdad** (por ejemplo, «GPU · 37/37 capas · Vulkan0 (NVIDIA GeForce RTX 4060)»).
- **ARRANCAR** la aplica. Con **Recordar y no volver a preguntar al abrir** (marcado por defecto) no vuelve a preguntar.
- Para cambiarla después: *Sistema → MOTOR Y CPU/GPU/NPU* (junto a *Redetectar*).
- Desde la terminal: `python -m nexus run --motor llamaserver --acelerador gpu` (cualquiera de las dos opciones fija la elección y no pregunta).

Perfiles de hardware (2.2)

Un **perfil** guarda de una vez cómo usar tu equipo: motor, acelerador, GPU, modelo, contexto, capas en la GPU y dónde va la memoria de la conversación (caché KV: en la **VRAM**, más rápida, o en la **RAM**, para que quepa un modelo más grande en una gráfica pequeña), y si se bloquea el modelo en RAM (`--mlock`).

Perfil de serie	Para qué
Automático	Lo decide Nexus-Office según el equipo (como siempre)
Rendimiento	GPU, modelo entero en la VRAM y contexto máximo
Equilibrado	GPU si la hay, contexto moderado (8192)
Modelo grande	Parte del modelo en la VRAM y el resto y el contexto en la RAM (bloqueada)
Ahorro	CPU, contexto corto (2048) y la mitad de los hilos: menos consumo
Solo CPU	Sin GPU ni NPU

Se elige en el menú **PERFIL** de la barra superior, que muestra solo lo que tu hardware permite. **Editar perfiles** crea, copia o cambia los tuyos (si cambias uno de serie y lo borras, vuelve a ser el original). Al activar uno, Nexus-Office reinicia el motor con esos valores. API: `GET /api/hw/perfiles`, `PUT` y `DELETE /api/hw/perfiles/{id}`, `POST /api/hw/perfiles/{id}/activar`. Configuración: `hardware.perfil` y `hardware.perfiles`.

Equipos con dos o más GPU y Linux (2.2)

- llama-server se arranca con `--device` para la GPU elegida (la lista sale de `llama-server --list-devices`). Antes podía caer en la integrada aunque hubiera una dedicada, o repartir capas entre las dos.
- En el menú **IA** eliges la GPU cuando hay más de una (`POST /api/hw/gpu`, `hardware.gpu`). En *Automático* se prefiere la dedicada con más VRAM.
- Los dispositivos **de software** (llvmpipe, lavapipe, SwiftShader) no se usan nunca: en Linux sin driver de Vulkan aparecían como «GPU» e iban más lentos que la CPU. Si es lo único que hay, se queda en CPU y lo dice.
- El nombre de la GPU se reconoce aunque llama.cpp le añada sufijos (por ejemplo «Intel(R) UHD Graphics 770 (ADL-S GT1)»).
- Si la GPU elegida falla al arrancar, Nexus-Office vuelve a la CPU y lo muestra en el menú **IA** (`gpu_error`).

No se ha podido probar con dos GPU físicas; la elección se ha probado con la salida real de `--list-devices` de varios equipos.

Motores

Motor	Qué es	CPU	GPU	NPU	Visión
Automático	El mejor disponible (normalmente llama-server)	✓	✓	✓	✓
llama-server	llama.cpp oficial como proceso aparte	✓	CUDA, Vulkan, Metal	OpenVINO (Intel), Hexagon (Android)	✓
llama.cpp integrado	llama-cpp-python dentro de Nexus-Office	✓	Metal en Mac	—	—

Los dos motores van **incluidos en los instaladores offline**, con su runtime: no se descarga nada al elegirlos. El integrado se instala desde el propio paquete la primera vez que lo eliges (unos segundos, sin internet).

Ollama ya no aparece en el selector porque es otra aplicación que hay que instalar aparte y no viene en el paquete. Si lo tienes instalado, Nexus-Office lo sigue usando cuando no hay otro motor.

Aceleradores

- **CPU**: siempre disponible. El modelo no usa la GPU aunque la haya.
- **GPU**: NVIDIA con CUDA; AMD, Intel, NVIDIA, Adreno, Mali o Raspberry Pi 5 con Vulkan; Mac con Metal; en Android, la GPU del móvil (OpenCL o Vulkan). Con una GPU integrada se avisa de que puede ir más lenta que la CPU con modelos grandes.
- **NPU**:
- **Intel Core Ultra (AI Boost)**, Windows x64 y Linux x86_64: llama-server con **OpenVINO** en la NPU (`GGML_OPENVINO_DEVICE=NPU`). La NPU trabaja con grafos fijos, así que se usa una sola conversación a la vez y un contexto de hasta 4096 tokens.
- **Snapdragon con Hexagon v73 o posterior** (app Android autónoma): llama.cpp en la NPU (HTP). Si el driver del móvil no lo permite, pasa solo a la GPU y luego a la CPU.
- **AMD Ryzen AI, Apple Neural Engine y Qualcomm en Windows**: llama.cpp no puede ejecutar ahí el modelo de texto. El selector lo dice y usa la GPU (o la CPU). Esas NPU se siguen usando para embeddings y voz cuando su runtime está instalado.

Cómo se comprueba que acelera de verdad

Tras arrancar llama-server, Nexus-Office lee su registro (`logs/llama-server.log`) y anota el dispositivo real: capas cargadas en la GPU, dispositivo CUDA, Vulkan o Metal, la NPU Hexagon u OpenVINO. Si lo pedido no se ha cumplido (por ejemplo, falta el driver de la GPU), lo dice en el selector y en el registro, y el modelo sigue en lo que sí funciona.

Runtimes incluidos por instalador

Instalador	llama-server	Motor integrado	NPU
Windows x64	CPU, Vulkan, CUDA 12	llama-cpp-python (CPU)	OpenVINO (Intel AI Boost)
Windows ARM64	CPU, Vulkan	llama-cpp-python x64 (emulado)	—
Linux x86_64 (.deb, .run, AppImage, Flatpak)	CPU, Vulkan, CUDA 12	llama-cpp-python (CPU)	OpenVINO (Intel AI Boost)
Linux ARM64 y Raspberry Pi	CPU, Vulkan, CUDA (Jetson)	llama-cpp-python (CPU, NEON)	—
macOS Apple Silicon	CPU, Metal	llama-cpp-python (Metal)	—
macOS Intel	CPU	llama-cpp-python (CPU)	—
Android autónoma	CPU, OpenCL/Vulkan	—	Hexagon HTP

Los runtimes del selector (llama-cpp-python y llama-server con OpenVINO) se compilan y prueban con `.github/workflows/selector-runtimes.yml` y la construcción de los instaladores los toma de ahí.

Configuración

- `llm.engine`: `auto`, `llamaserver` o `llamacpp`.
- `hardware.accel`: `auto`, `cpu`, `gpu` o `npu`.
- `hardware.llama_variant`: variante de llama-server elegida (`cpu`, `vulkan`, `cuda`, `metal`, `openvino`).
- `startup.ask_accel`: `true` para preguntar al arrancar.

API: `GET /api/accel` (opciones, elección y dispositivo efectivo), `POST /api/accel {engine, accel, remember}`, `POST /api/accel/test` (genera 16 tokens y mide).

Motores de inferencia por hardware

Desde la 4.0.0 Agente IA (edición Python) elige el **motor de inferencia** que mejor acelera el chip del equipo donde se ejecuta, en lugar de usar siempre llama.cpp. Cada fabricante tiene su motor optimizado: los kernels de TensorRT-LLM para NVIDIA, OpenVINO para la NPU de Intel, Genie o ONNX Runtime con QNN para la NPU Hexagon de Qualcomm, LiteRT-LM para la TPU de los Pixel... llama.cpp sigue de respaldo en todos los equipos.

Motores

Motor	Aceleradores	Formato de modelo	Va en el paquete offline
ONNX Runtime GenAI	CUDA, DirectML (cualquier GPU en Windows), QNN (NPU Snapdragon X), OpenVINO, VitisAI (NPU Ryzen AI), CPU	carpeta con `genai_config.json`	Windows x64 (DirectML), Windows ARM64, Linux, macOS
OpenVINO GenAI	NPU Intel Core Ultra, iGPU Xe y Arc, CPU	carpeta con `openvino_model.xml`	Windows x64, Linux x86_64, macOS
LiteRT-LM	NPU de Tensor, Snapdragon, MediaTek e Intel; GPU; CPU (XNNPACK)	`.litertlm`	Windows x64 (con NPU Intel), Linux, macOS Apple Silicon (rueda `litert-lm-api` y `motores-npu.yml`)
ExecuTorch	XNNPACK (CPU), QNN, Vulkan, CoreML, MPS (según el `.pte`)	`.pte` + tokenizer	Windows x64 y macOS Apple Silicon; en Linux aparte (arrastra torch con CUDA, unos 3 GB): `nexus setup --all` con internet
MLC LLM	CUDA, ROCm, Vulkan, Metal, OpenCL (Adreno, Mali)	carpeta con `mlc-chat-config.json`	aparte (no hay rueda en PyPI): `nexus setup --all` con internet
TensorRT-LLM	NVIDIA (Tensor Cores)	checkpoint de Hugging Face o `rank0.engine`	aparte (varios GB): `nexus setup --all` con internet
Qualcomm Genie	NPU Hexagon (HTP)	carpeta de Qualcomm AI Hub con `genie_config.json`	Windows ARM64 y Linux ARM64 (QAIRT, de `motores-npu.yml`)
llama.cpp	CPU, CUDA, ROCm, Vulkan, Metal, SYCL	`.gguf`	siempre (respaldo)

Si falta el paquete o la biblioteca de un motor, Agente IA dice por qué y usa el siguiente.

Android (APK autónoma), desde la 4.0.2

El Python de la app usa su propio cargador (musl) y no puede cargar con ctypes las bibliotecas de Android (bionic). Por eso en el móvil cada motor corre fuera del proceso de Python (`nexus/motores/auxiliar.py`):

Motor	Cómo va en el móvil	Aceleradores
Qualcomm Genie (QNN)	proceso nativo `libnexusmotor.so motor genie` (el ejecutable Android de la edición C++)	NPU Hexagon v68 a v81 (Snapdragon 8 Gen 1 a 8 Elite Gen 5)
LiteRT-LM	proceso nativo `libnexusmotor.so motor litert`, con el dispatch de NPU de Qualcomm, MediaTek y Google Tensor	NPU, GPU (OpenCL/WebGPU), CPU
ONNX Runtime GenAI	proceso nativo `libnexusmotor.so motor onnx`, ONNX Runtime con el proveedor QNN	NPU (QNN), CPU
ExecuTorch	puente Java de la app (`MotorExecuTorch.java`, `LlmModule`) en 127.0.0.1 con clave	CPU (XNNPACK), NPU (delegado QNN, si el `.pte` lo lleva)
llama.cpp	`llama-server` (como antes)	CPU, GPU (OpenCL/Vulkan), NPU Hexagon
TensorRT-LLM, OpenVINO GenAI, MLC LLM	**no aplican** en Android: se muestran aparte en *Sistema → Motores* con el motivo	—

Todas las bibliotecas van en `lib/arm64-v8a` de la APK (Android solo deja ejecutar código nativo desde ahí) y las recoge `apk.yml`: LiteRT-LM y QAIRT 2.42 (Genie, QNN HTP) de `motores-npu.yml`, ONNX Runtime 1.29 con QNN y ONNX Runtime GenAI 0.19 de Maven y NuGet, ExecuTorch 1.5.1 con QNN de Maven, y el proceso auxiliar de la Release v3.2.3-cpp. La NPU busca sus programas (skel) en `ADSP_LIBRARY_PATH`, que apunta a esa carpeta.

Modelos para la NPU del móvil: los `.litertlm` del catálogo se descargan en la versión compilada para el SoC del móvil si el repositorio la tiene (`..._sm8750.litertlm` en un Snapdragon 8 Elite); si no, la general (GPU y CPU). LiteRT-LM solo

prueba la NPU con modelos compilados para un SoC. Genie usa carpetas de Qualcomm AI Hub (`genie_config.json` y los `.bin` del Snapdragon concreto): se importan desde *Modelos → Importar*.

Qué motor va con cada chip

Agente IA resume el hardware en una familia y parte de este orden (ver `nexus/motores/chips.py`):

Chip	Orden de partida
Snapdragon (móvil y X Elite/Plus)	Genie (NPU) → ONNX Runtime QNN → LiteRT-LM NPU → ExecuTorch QNN → MLC (Adreno) → llama.cpp
Google Tensor	LiteRT-LM NPU → LiteRT-LM GPU → MLC → ExecuTorch → llama.cpp
MediaTek, Exynos	LiteRT-LM NPU → LiteRT-LM GPU → MLC → ExecuTorch → llama.cpp
NVIDIA	TensorRT-LLM → ONNX Runtime CUDA (→ DirectML en Windows) → MLC CUDA → llama.cpp CUDA
AMD	(Windows: NPU Ryzen AI con VitisAI) → ONNX Runtime DirectML/ROCm → MLC → ExecuTorch Vulkan → llama.cpp
Intel	OpenVINO NPU → OpenVINO GPU → ONNX Runtime OpenVINO → DirectML/MLC → OpenVINO CPU → llama.cpp
Apple Silicon	MLC Metal → llama.cpp Metal → ExecuTorch MPS
Solo CPU	llama.cpp → OpenVINO CPU (x86) o LiteRT-LM (ARM) → ONNX Runtime CPU → ExecuTorch

El banco manda sobre la tabla

La tabla es solo el punto de partida. En **Sistema → Motores de inferencia → MEDIR TODOS LOS MOTORES** (o `nexus motores banco` en la terminal) Agente IA genera una respuesta corta con cada modelo de texto instalado en su motor y mide los **tokens por segundo** y el **tiempo hasta el primer token**. Desde ese momento se elige el más rápido medido en tu equipo, aunque la tabla diga otra cosa (por ejemplo, si en tu portátil llama.cpp en la iGPU supera a OpenVINO en la NPU). El resultado queda en `data/motores/banco.json`.

Entre los modelos medidos que van cómodos (8 tokens/s o más) se elige **el mayor**, que suele responder mejor, y a igual tamaño el motor más rápido. Si ninguno llega a esa velocidad, el más rápido. Antes de medir se pide una respuesta mínima para que la carga del modelo (que se apunta aparte) no cuente en el tiempo hasta el primer token. Al cambiar de motor se descarga el modelo del anterior para no tener dos en memoria.

```
python -m nexus motores          # chip, orden, motores instalados y modelos con su motor
python -m nexus motores banco    # mide todos y muestra la tabla de tokens/s
```

Aceleradores y caídas

Cada motor prueba sus aceleradores en orden (por ejemplo NPU → GPU → CPU). Si uno no arranca con un modelo, se recuerda y se usa el siguiente. Mientras un motor carga o genera, Agente IA deja una marca en disco: si el proceso se cae (un driver de NPU o GPU que falla), al volver a arrancar esa combinación queda apuntada como **caída** y no se usa hasta pulsar *OLVIDAR CAÍDAS*.

Se puede fijar el motor y el acelerador en el mismo panel, o en `config.yaml`:

```
llm:
  motor: auto            # auto | onnx | openvino | litert | executorch | mlc | tensorrt | genie | llamaserver
  motor_acelerador: ""   # "" = automático; p. ej. NPU, GPU, CPU (OpenVINO), cuda, dml, qnn (ONNX), npu (LiteRT)
```

Modelos para cada motor

En **Modelos** aparecen, además de los GGUF, los recomendados para los motores de tu chip:

Modelo	Motor	Repositorio
Qwen2.5 1.5B int4	OpenVINO	`OpenVINO/Qwen2.5-1.5B-Instruct-int4-ov`
Phi-3.5 mini int4	OpenVINO	`OpenVINO/Phi-3.5-mini-instruct-int4-ov`
Qwen3 8B int4	OpenVINO	`OpenVINO/Qwen3-8B-int4-ov`
Phi-4 mini (CPU/QNN)	ONNX Runtime GenAI	`microsoft/Phi-4-mini-instruct-onnx` (`cpu_and_mobile/...`)

Modelo	Motor	Repositorio
Phi-4 mini (GPU)	ONNX Runtime GenAI	`microsoft/Phi-4-mini-instruct-onnx` (`gpu/...`)
Qwen2.5 1.5B / Gemma 4 E2B	LiteRT-LM	`litert-community/...`
Qwen2.5 1.5B / Qwen3 4B q4f16	MLC LLM	`mlc-ai/...-MLC`
Qwen3 4B 8da4w	ExecuTorch	`pytorch/Qwen3-4B-INT8-INT4`
Qwen2.5 1.5B	TensorRT-LLM	`Qwen/Qwen2.5-1.5B-Instruct` (se compila para tu GPU la primera vez)

Los modelos de Genie salen de Qualcomm AI Hub compilados para cada Snapdragon: se importan como carpeta en *Modelos → Importar*. También se puede importar cualquier carpeta o fichero de estos formatos: Agente IA reconoce el formato y lo asigna a su motor.

Pruebas

- `tests/test_motores.py`: formatos, matriz por chip, selector, banco, caídas y backend con un motor simulado.
- `.github/workflows/motores-python.yml`: descarga modelos reales y mide llama.cpp, ONNX Runtime GenAI y OpenVINO GenAI en los runners de GitHub (CPU x86_64 y ARM64); la tabla queda en el resumen de la ejecución.
- Primera medida en los runners (2026-11-10, solo CPU, respuesta corta):

Runner	Modelo	Motor	tok/s	1.er token
x86_64	Qwen2.5 1.5B	llama.cpp (Q4_K_M)	24.7	4.50 s
x86_64	Qwen2.5 1.5B	OpenVINO (int4)	15.3	7.41 s
x86_64	Phi-4 mini	ONNX Runtime GenAI (int4)	12.0	6.65 s
x86_64	Phi-4 mini	llama.cpp (Q4_K_M)	10.5	4.04 s
x86_64	Phi-3.5 mini	OpenVINO (int4)	5.2	17.68 s
ARM64	Qwen2.5 1.5B	llama.cpp	31.5	2.21 s
ARM64	Phi-4 mini	llama.cpp	12.8	3.82 s
ARM64	Phi-4 mini	ONNX Runtime GenAI	12.1	5.05 s

En CPU pura llama.cpp sigue siendo igual o más rápido salvo Phi-4 mini en x86 con ONNX Runtime: la ventaja de los otros motores está en la NPU y la GPU, y por eso manda el banco de cada equipo. - Las NPU y GPU no se pueden probar en GitHub: se miden en el equipo de cada usuario con el banco.

Importar grafos como conocimiento

Nexus-Office puede incorporar a su conocimiento un grafo de **cualquier tipo y formato**: una red exportada de Gephi o Cytoscape, una base de Neo4j, una ontología RDF u OWL, un diagrama Mermaid, una hoja de Excel con nodos y relaciones, un mapa mental o la base de otro Nexus-Office. Todo funciona sin internet.

El formato se reconoce **por el contenido**. La extensión solo ayuda cuando el contenido no basta: un GraphML guardado como `.txt` o un JSON sin extensión se leen igual.

Lo importado se **fusiona** con lo que Nexus-Office ya sabe. Los nodos con el mismo nombre se unen en uno, las relaciones que ya existían se refuerzan y no se duplican, y cada nodo conserva su nota, su tipo y su categoría si ya los tenía. Desde ese momento los agentes lo usan al responder.

Cómo se importa

Desde la app

1. Entra en modo administrador y abre **Ajustes > Gestor de conocimiento > Importar / exportar**.
2. En **Insertar en**, elige dónde va lo importado: - **Automático**: cada nodo va a su sitio. Lo común (personas, lugares, preferencias) va al grafo general y el saber hacer de un oficio va al agente especialista. - **General**: para todos los agentes. - **Un agente**: solo para ese agente.
3. Suelta el fichero en el recuadro, o haz clic para elegirlo. Puedes soltar **varios ficheros a la vez**, por ejemplo `nodes.csv` y `edges.csv`, y se unen en un solo grafo.
4. La importación va en segundo plano y se ve su avance abajo. Al terminar, un aviso indica el formato reconocido, cuántos nodos son nuevos, cuántos se han fusionado con los que ya había y cuántas relaciones se han creado.

En **Formatos admitidos** se despliega la lista completa.

Desde la terminal

```
python -m nexus grafo formatos                                  # lista de formatos
python -m nexus grafo importar red.graphml                      # al grafo general
python -m nexus grafo importar nodes.csv edges.csv --en auto    # varios ficheros, cada nodo a su sitio
python -m nexus grafo importar recetas.ttl --en cocinero        # solo para el agente «cocinero»
python -m nexus grafo exportar copia.json --en todo             # exportar (json, graphml o csv con --formato)
```

Desde el chat

Los agentes tienen la herramienta `graph_import`. Puedes pedirles, por ejemplo, «importa como conocimiento el grafo `proveedores.gexf` de la carpeta de trabajo» o «guarda este diagrama como conocimiento: Pedido -> Albarán -> Factura». El agente lee un fichero de su carpeta de trabajo (`data/sandbox`) o el texto que le das, y lo guarda en el grafo general, en el suyo o repartido automáticamente.

Dentro de un ZIP

Al **leer un ZIP** (también RAR, 7z o TAR) en **Ajustes > Gestor de conocimiento > Leer un ZIP**, los grafos que trae se importan solos, en cualquiera de estos formatos, y el resto de documentos va a la biblioteca.

Formatos admitidos

Familia	Extensiones habituales	Qué se lee
Nexus-Office	`.json`, `.db`	Exportación propia y la base SQLite de otro Nexus-Office, respetando el grafo general y el de cada agente.
JSON node-link	`.json`	D3, vis.js, sigma.js, NetworkX (`node_link_data` y `adjacency_data`), JSON Graph Format, Arrows.app.
Cytoscape	`.cyjs`, `.cx`, `.cx2`, `.sif`, `.xgmml`	Cytoscape.js, CX y CX2, SIF y XGMML.
Neo4j	`.json`, `.jsonl`, `.csv`, `.cypher`	Exportación del Browser, API HTTP, APOC (JSON, Cypher y GraphML) y CSV de `neo4j-admin import` (`:ID`, `:START_ID`, `:END_ID`, `:TYPE`, `:LABEL`).

Familia	Extensiones habituales	Qué se lee
Cypher	`.cypher`, `.cql`	`CREATE`, `MERGE` y `MATCH … CREATE`, a mano o exportado. Las consultas (`MATCH … RETURN`) no crean nada.
JSON-LD	`.jsonld`, `.json`	schema.org, Wikidata y cualquier `@graph`.
GraphSON	`.json`, `.graphson`	TinkerPop, JanusGraph y Amazon Neptune, con tipos o sin ellos.
RDF	`.ttl`, `.nt`, `.nq`, `.trig`, `.n3`, `.rdf`, `.owl`	Turtle, N-Triples, N-Quads, TriG, N3, RDF/XML y ontologías OWL.
GraphML	`.graphml`	yEd (con sus etiquetas), Gephi, NetworkX, igraph y APOC.
GEXF	`.gexf`	Gephi, con sus atributos.
GML	`.gml`	igraph, NetworkX y Cytoscape.
Graphviz DOT	`.dot`, `.gv`	`digraph` y `graph`, con etiquetas y pesos.
Análisis de redes	`.net`, `.paj`, `.gdf`, `.dl`, `.tgf`, `.lgl`, `.ncol`	Pajek, GDF (GUESS/Gephi), UCINET DL, TGF, LGL y NCOL.
Tablas	`.csv`, `.tsv`, `.xlsx`, `.ods`, `.db`, `.sqlite`	Tablas de aristas (`source,target,relation`), de nodos (`id,label,…`), matrices de adyacencia, tripletas y ConceptNet. En Excel y ODS, cada hoja es una tabla. En SQLite, cada tabla.
Listas	`.edgelist`, `.adjlist`, `.txt`	`a b [peso]`, `A: B, C` y una tripleta por línea.
Diagramas	`.mmd`, `.puml`, `.txt`	Mermaid (flowchart, graph, erDiagram, classDiagram, mindmap), PlantUML y texto con flechas `A -> B : relación`.
Mapas mentales y esquemas	`.mm`, `.opml`, `.xmind`, `.md`	FreeMind y Freeplane, OPML, XMind y listas o títulos con sangría.
Notas enlazadas	`.md`, `.canvas`, `.zip`	Obsidian, Logseq y Foam (`[[enlaces]]`) y Obsidian Canvas.
YAML y TOML	`.yaml`, `.yml`, `.toml`	Con nodos y aristas, con tripletas o con cualquier estructura de objetos con nombre.
Comprimidos	`.zip`, `.tar`, `.gz`, `.bz2`, `.xz`	Uno o varios grafos dentro, en cualquiera de los formatos anteriores.

Si el fichero no tiene forma de grafo (un PDF, una foto, código fuente, una página web), Nexus-Office lo dice y propone llevarlo a la **Biblioteca**.

Qué se guarda de cada grafo

- **Nodos**: cada entidad del grafo, con su nombre (`name`, `label`, `title`, `rdfs:label`…) y su tipo (la etiqueta de Neo4j, el `rdf:type`, la columna `type`…).
- **Relaciones**: las aristas, con su nombre en minúsculas y con guiones bajos (`TRABAJA_EN` y `trabajaEn` quedan como `trabaja_en`). Si no tienen nombre, quedan como `relacionado_con`. El peso se conserva.
- **Atributos**: las propiedades de cada nodo (propiedades de Neo4j, literales RDF, columnas de una tabla, atributos de GEXF o GraphML) van a su **nota** como `clave: valor`. Los agentes los ven al hablar de esa entidad: si importas que el Teide tiene `altura: 3718`, el agente lo sabe al preguntarle por el Teide.
- **Nodos anónimos de RDF**: se resuelven para que el conocimiento quede entre entidades con nombre. `ex:Ana ex:vive [ ex:ciudad ex:Bilbao ]` queda como *Ana vive_ciudad Bilbao*.
- **Ámbitos**: el grafo de otro Nexus-Office mantiene lo que era general y lo que era de cada agente, si ese agente existe aquí.

Un grafo puede tener hasta 200.000 nodos y la subida, hasta 300 MB. Un grafo de 100.000 relaciones se lee y se inserta en pocos segundos.

Para desarrolladores

- La lectura está en `nexus/memory/kg_formats.py`: `parse_bytes(datos, nombre)` detecta el formato con `detect()` y devuelve `{"format", "nodes", "edges"}`. `parse_many([(nombre, datos), …])` une varios ficheros; las tablas comparten ids, de modo que `nodes.csv` y `edges.csv` forman un solo grafo.
- La fusión está en `nexus/memory/kg_io.py`: `insert_graph(grafo, leido, destino, organizador, agentes)` devuelve `nodes`, `new`, `merged`, `relations`, `skipped` y `by_scope`.
- Lo que dentro de un ZIP de documentos cuenta como grafo lo decide `looks_like_graph()`: las interpretaciones de último recurso (un JSON o YAML cualquiera, un esquema con sangría) llevan `generic: true` y no cuentan.
- API: `POST /api/kg/import` acepta `file` o varios `files`; `GET /api/kg/formats` da la lista de formatos. Ver API.md.

- Pruebas: `tests/test_graph_import.py`, con un ejemplo real de cada formato.

Biblioteca RAG y conversión URL → PDF

RAG (generación aumentada por recuperación)

- **Formatos de documento**:
- PDF, por páginas.
- Word (DOCX).
- OpenDocument: ODT, ODS y ODP.
- PowerPoint (PPTX) y Excel (XLSX), por diapositiva u hoja.
- EPUB, por capítulo.
- RTF, HTML, Markdown, TXT, CSV, JSON y YAML.
- Código fuente, con más de 80 extensiones.

Cada documento se copia en `data/rag/files/`, así que la biblioteca viaja con la carpeta. `GET /api/rag/formats` devuelve la lista exacta. - **Archivos comprimidos**: ZIP, RAR, 7z y TAR (`.tar`, `.tar.gz`/`.tgz`, `.tar.bz2`, `.tar.xz`). Ver la sección siguiente. - **Importación en lote**: suelta muchos ficheros a la vez en la Biblioteca, sueltos y comprimidos mezclados. Se envían en tandas de 20 a `POST /api/rag/import` (multipart, campo `files`). La respuesta trae `results` (uno por fichero, en el mismo orden), `ok`, `failed` y `seconds`. Si un fichero falla, se informa de él y los demás se importan igualmente. - **Troceado** por párrafos (~900 caracteres, solapamiento de 150) con número de página. - **Búsqueda híbrida**: `0,7 × similitud semántica + 0,3 × coincidencia de términos`. Usa el mismo motor de embeddings que la memoria (sentence-transformers › Ollama › hashing). - **En cada mensaje**, los 3 fragmentos más relevantes (si superan el umbral) se añaden al contexto del agente con su fuente; el modelo cita como `[n]`. Sin LLM, el núcleo integrado responde citando los fragmentos. - **Herramientas**: `rag_search`, `rag_list`, `url_to_pdf` y `crawl_docs`. - **Interfaz**: *Núcleo → Biblioteca RAG*: procesar URL, rastrear documentación, arrastrar documentos, buscar, abrir, mover de grafo y borrar.

Leer páginas como un navegador (2.2)

Muchas webs (tiendas, documentación hecha con React, Vue o Angular, paneles) llegan casi vacías y se pintan después con JavaScript. Para que la Biblioteca, *URL a PDF*, el rastreador y la herramienta web de los agentes lean lo mismo que tú:

- Nexus-Office busca un **Chrome, Edge, Chromium o Brave** en el equipo (Windows, macOS y Linux, también el `chrome-headless-shell` de Playwright) y lo abre **sin ventana** (`--headless --dump-dom`), dejando unos segundos para que la página ejecute su JavaScript. Se queda con el DOM final y lo procesa como cualquier HTML.
- **Cuándo**: en *Automático* solo si la página lo necesita (un `<div id="root">` o `__next` vacío, `<noscript>` que pide JavaScript, muchos scripts y poco texto). *Siempre como navegador* lo hace con todas; *Nunca* lo apaga. Se cambia en el menú **MEMORIA** de la barra superior o con `rag.browser` (`auto`, `siempre`, `nunca`).
- **Seguridad**: el navegador usa un perfil propio de Nexus-Office (no el tuyo), que se vacía de cookies y almacenamiento antes de cada lectura, y sale a internet por un proxy propio que **solo deja llegar a direcciones públicas** (nada de `localhost`, la red local ni los metadatos de la nube), salvo que se active `rag.allow_private_urls`. Como mucho hay dos navegadores a la vez.
- Si no hay navegador, o tarda más de 40 s, se usa la descarga normal y se avisa en la respuesta.
- Un administrador puede fijar uno concreto con `rag.browser_path`. `GET /api/rag/navegador` dice el modo y el navegador encontrado. La herramienta `web_fetch` de los agentes indica `"navegador": true` cuando lo ha usado.

Grafo general o grafo de un agente

El grafo de conocimiento tiene un **grafo general**, común a todos los agentes, y dentro de él un **subgrafo aislado por agente**.

- **Importar en → grafo general**: el documento lo consultan todos los agentes y su nodo entra en el grafo general.
- **Importar en → solo un agente**: solo ese agente lo encuentra (en el contexto de cada mensaje y con `rag_search`/`rag_list`), y el documento entra en su grafo individual. Su resumen y puntos clave, si es una URL o un rastreo, quedan como recuerdos privados de ese agente.
- El selector afecta a documentos sueltos, comprimidos, URL → PDF y rastreo. En la lista, cada documento muestra su grafo y un desplegable para moverlo; el nodo se mueve con él.

- Un agente puede importar para sí mismo con `url_to_pdf` o `crawl_docs` y `target: "agente"`. Por defecto se importa al general.
- Si se borra un agente, sus documentos pasan al grafo general.
- En la conversación, lo que se sabe del usuario (perfil, gustos, pautas, relaciones) va al grafo general. El resto lo reparte el organizador: el saber hacer de una especialidad va al subgrafo de ese agente y el conocimiento común, al general. Ver MEMORIA.md.
- *Ajustes → Gestor de conocimiento → Leer un ZIP* hace más que importarlo: inserta los grafos que traiga, agrupa los documentos por temas y los razona con el LLM. Ver MEMORIA.md.

Archivos ZIP, RAR, 7z y TAR con proyectos o documentación

Un archivo comprimido se puede adjuntar en el **chat** (botón 📎) o soltar en la **Biblioteca RAG**. Nexus-Office:

1. **Descomprime** el archivo de forma segura en `data/sandbox/proyectos/<nombre>/`. Si todo cuelga de una única carpeta raíz, se aplana. Si el nombre ya existe, se usa `<nombre>_2`, `<nombre>_3`…
2. **Indexa** en la biblioteca los documentos (PDF, DOCX, HTML, MD, TXT…) y el código y la configuración (más de 80 extensiones, además de `Dockerfile`, `Makefile`, `README`…) como **un único documento** del tipo `zip`, `rar`, `7z` o `tar`. Cada fragmento lleva delante la ruta del fichero (`[proyectos/x/src/main.py]`), así que las citas dicen de qué fichero sale. La primera página es la **estructura** del proyecto.
3. En el chat, el mensaje lleva una nota con la carpeta, para que el agente pueda explorarla con `file_list` (con `path`) y `file_read` y buscar con `rag_search`. Sin texto, pide un resumen del contenido.

Herramientas de descompresión:

Formato	Cómo se descomprime
ZIP y TAR	Con la biblioteca estándar de Python, sin instalar nada
RAR	Con el primer programa disponible: `unrar`, `7z` (con el códec RAR), `bsdtar` o `unar`
7z	Con `7zz`/`7z`/`7za`, `bsdtar` o `unar`

Si no hay ninguno, Nexus-Office dice qué instalar:

- Windows: 7-Zip o WinRAR. En Windows 10/11 también vale el `tar` del sistema.
- Ubuntu y WSL: `sudo apt install unrar 7zip`. El paquete `7zip` de Debian/Ubuntu no trae el códec RAR, así que para RAR instala `unrar` (o `unar`).
- macOS: `brew install sevenzip` o `brew install unar`.
- Termux: `pkg install unrar p7zip`.

Los programas externos descomprimen primero en una carpeta de cuarentena. Nexus-Office lee antes el listado del archivo para aplicar los mismos límites que al ZIP. Después revisa cada fichero, como con el ZIP, antes de moverlo a su carpeta. Los ficheros cifrados o dañados se descartan y se informa de ellos.

Seguridad y límites: - Rechaza rutas absolutas, con `..` o con unidad de Windows (*zip slip*), enlaces simbólicos y entradas cifradas. - Contra bombas ZIP: 20 000 ficheros, 1 GB descomprimido, 50 MB por fichero y ratio de compresión ≤ 200 (se comprueba el tamaño real al descomprimir, no el declarado). - No descomprime `.git`, `node_modules`, `__pycache__`, `venv`/`.venv`, `dist`, `build`, `target` ni similares. - No indexa (aunque sí descomprime) `.env`, claves (`.pem`, `.key`, `id_rsa`…), minificados, mapas, lockfiles ni `vendor`/`third_party/`. Tampoco binarios. Por fichero indexa como máximo 512 KB, y en total hasta 20 000 ficheros. - **Proyectos grandes por partes**: lee los ficheros en grupos de 200 y, cuando una parte llega a 6 millones de caracteres, sigue en la siguiente. Las partes son documentos correlativos de la biblioteca («Proyecto X · parte 2 (ficheros 201-400)»). Borrar la primera borra todas, junto con el archivo y su carpeta. - Al borrar el documento de la biblioteca se borran también el archivo y su carpeta descomprimida.

Rendimiento: procesador al máximo

- **Lectura en paralelo**: en una importación en lote, cada documento suelto se lee en un núcleo distinto, con un pool de procesos (`nexus/parallel.py`). Los archivos comprimidos se procesan uno tras otro, porque cada uno ya usa el disco a fondo.
- **Embeddings**: el motor *hashing* reparte entre núcleos los lotes a partir de 256 fragmentos. Ollama recibe lotes de 128 y sentence-transformers de 64. Los fragmentos se guardan en la base de datos con una sola transacción.
- **Ajustes** (`performance` en la configuración):
- `workers`: número de procesos. 0 = automático, uno por núcleo disponible.

- `crawl_connections`: descargas simultáneas al rastrear. 0 = automático, entre 4 y 8.
- `NEXUS_NO_PROCESSES=1` fuerza hilos en lugar de procesos. En Android se hace solo.

Rastreo (crawling) de un sitio de documentación

Para que Nexus-Office aprenda una documentación entera (un manual, la API de una librería, la guía de un producto), dale la página inicial:

- **Interfaz**: *Núcleo → Biblioteca RAG*, fila **RASTREAR**: URL, máximo de páginas (40 por defecto, hasta 100 000) y ámbito (*esta sección* o *todo el dominio + grafo*). Con *todo el dominio* el máximo no se aplica. Se ejecuta en segundo plano y aparece en el panel de rastreos.
- **Chat**: *«Rastrea la documentación de https://docs.python.org/3/tutorial/ y apréndela»*. Con *«todo el dominio»* recorre el sitio entero. Sin LLM, el núcleo integrado lo reconoce y lanza la herramienta.
- **Herramienta** `crawl_docs` (`url`, `max_pages`, `max_depth`, `scope`, `background`, `job`, `continue`), del agente Investigador. **API**: `POST /api/rag/crawl {url, max_pages, max_depth, scope, background, batch_pages}`.

Cómo recorre el sitio: 1. **Ámbito**: por defecto, la carpeta de la URL inicial (`https://docs.x.org/3/tutorial/` → solo `/3/tutorial/…`); con `scope=domain`, todo el dominio registrable con todos sus subdominios (ver *Todo el dominio, sin excepciones* más abajo). Si la portada redirige (`/docs` → `/docs/es/latest/`), el ámbito se toma del destino. 2. **Recorrido en anchura** hasta `max_depth` saltos (3 por defecto). Sigue también los enlaces del menú lateral, aunque ese menú no se indexa. 3. **robots.txt**: respeta `Disallow` y `Crawl-delay` (como máximo 5 s). - Si el sitio declara `Crawl-delay`, Nexus-Office va de una en una página. - Si no, descarga varias páginas a la vez (`performance.crawl_connections`, de 4 a 8 por defecto) por conexiones reutilizadas (keep-alive), con al menos 0,1 s entre peticiones. - El análisis de cada página (extracción y deduplicación) se reparte entre los núcleos. - Los resultados se aplican en el orden de descubrimiento, así que el resultado es idéntico al de un rastreo secuencial, pero varias veces más rápido. 4. **sitemap.xml** (el declarado en robots.txt o `/sitemap.xml`, también índices de sitemaps) como semilla, filtrado por el ámbito. 5. **Descarta**: otros dominios, imágenes, CSS/JS, descargas y PDF, búsquedas, inicios de sesión, `_sources`/`_static`, páginas `noindex`, canónicas ya leídas, contenido duplicado y páginas casi vacías. Quita los parámetros de seguimiento (`utm_*`, `fbclid`…) y los `#fragmentos`. 6. **Extracción** de cada página con el mismo extractor estructurado que URL → PDF.

Qué guarda: - **Un único documento** del tipo `web` en la biblioteca, una página por página rastreada. Cada fragmento lleva delante su URL (`[https://docs.x.org/3/tutorial/classes.html]`), así que las citas dicen de qué página sale. - Una **copia legible en Markdown** con índice (botón *ABRIR*), en `data/rag/files/`. - **Asimilación**: resumen y puntos clave a la memoria; el sitio al grafo de conocimiento (`ha_leido`, `trata_de`, `contiene` con los títulos de las páginas). - **Volver a rastrear** la misma URL y ámbito **actualiza** el documento: el anterior se borra al terminar el nuevo.

Todo el dominio, sin excepciones (2.0)

Con el ámbito **todo el dominio** Nexus-Office lee el sitio entero, tenga las páginas que tenga: - **Sin límite** de páginas ni de profundidad. `max_pages` y `max_depth` se ignoran. - **Todos los subdominios** del dominio registrable (`www.`, `blog.`, `docs.`…; también `.co.uk`, `.com.es` y similares), cada uno con su propio `robots.txt`. - **Documentos enlazados**: PDF, Word, LibreOffice (odt, ods, odp), PowerPoint, Excel, EPUB, RTF, texto, CSV y Markdown, hasta 60 MB cada uno, con los mismos lectores de la biblioteca RAG. Las URL que aparecen dentro del texto de un documento también se siguen. - **Páginas cortas** (desde 5 palabras): glosarios, fichas y avisos también entran. - **Sitemaps**: hasta 2000 ficheros de sitemap (índices incluidos). - Siempre en **segundo plano y por lotes**; si se cierra Nexus-Office, el trabajo **se reanuda solo** al volver a arrancar. - Solo quedan fuera lo que el sitio prohíbe en `robots.txt`, otros dominios, imágenes, CSS/JS, binarios y el contenido duplicado.

Grafo de conocimiento multicapa del dominio

Al terminar, el rastreo construye un **grafo propio del dominio** en `data/rag/crawls/<id>.kg.sqlite`, por capas: 1. **Fuentes**: dominio, secciones (subdominios y carpetas), páginas y documentos, con sus enlaces. 2. **Conceptos**: términos clave de cada página y documento, relacionados por coaparición y por parecido semántico (modelo de embeddings). 3. **Afirmaciones**: frases con datos (cifras, fechas, definiciones). Se **contrastan entre fuentes**: las que dicen lo mismo en páginas distintas quedan como *contrastada (N fuentes)*; las que dan cifras distintas sobre lo mismo, como *discrepante*, con cada versión y su fuente; el resto, como *fuente única*. También se cotejan con los otros documentos de la biblioteca. Los textos de plantilla que solo cambian un número (por ejemplo, «Capítulo 1…», «Capítulo 2…») no cuentan como discrepancia. 4. **Temas**: grupos de conceptos muy relacionados. 5. **Síntesis razonada**: con el modelo de IA activo, cada tema recibe un resumen y sus conclusiones, que razona solo a partir de las afirmaciones contrastadas y citando fuentes. Sin modelo, se queda en las capas anteriores.

En el panel de rastreos, cada trabajo de dominio muestra páginas, afirmaciones contrastadas y nodos, y tiene: - **CREAR GRAFO / REHACER GRAFO**: lo construye o lo vuelve a construir (por ejemplo, tras activar un modelo con razonamiento). - **⬇ ZIP**: descarga el **paquete de conocimiento** (`graph.json` en formato nexus-kg, `conocimiento.md` legible y `manifest.json`). - **DAR A AGENTE**: importa el grafo en el subgrafo de un agente (o en el general) y añade el texto de conocimiento a su biblioteca, así que el agente **adquiere ese conocimiento** y lo cita. - El ZIP se puede importar en otro Nexus-Office con **IMPORTAR CONOCIMIENTO DE DOMINIO (.zip)** en la *Biblioteca RAG* (va al grafo elegido en *Importar en*) (o `POST /api/rag/domain-knowledge/import`, con el fichero y el campo `agent`).

API: `POST /api/rag/crawls/{id}/knowledge` (construir), `GET /api/rag/crawls/{id}/knowledge` (ZIP), `POST /api/rag/crawls/{id}/knowledge/import` `{agent}`.

Rendimiento medido: 5000 páginas se añaden al grafo en unos 13 s y el grafo se construye en unos 3 s, con unos 350 MB de memoria.

Dominios enteros: rastreo por lotes

Un dominio grande no cabe de una vez, así que se procesa en **lotes correlativos** que se guardan según terminan: - Si `max_pages` supera el tamaño de lote, el rastreo se convierte en un **trabajo por lotes**. El lote depende de la RAM: 50 páginas con menos de 4 GB, 100 en móviles o con menos de 8 GB, 200 con menos de 16 GB y 300 a partir de ahí. `rag.crawl_batch_pages` lo fija a mano. - Cada lote es un documento propio, ordenado: «Documentación: X · lote 003 (págs. 401-600)». El resumen y los puntos clave se hacen con el primero. - Tras cada lote se guarda el trabajo en `data/rag/crawls/<id>.json`: la cola de URLs pendientes en orden de descubrimiento, las visitadas y las huellas del contenido. Al **reanudar** (después de pausar, de reiniciar Nexus-Office o de un corte) sigue por la página siguiente, sin repetir ninguna y en el mismo orden. - **Panel de rastreos** en la Biblioteca RAG: progreso, lotes y cola pendiente de cada trabajo, con **PAUSAR**, **REANUDAR** y ✕ (borra el trabajo y, si quieres, sus documentos). Un trabajo en curso cuando Nexus-Office se cerró aparece como *interrumpido* y se reanuda igual. - **Chat**: «aprende todo el dominio https://docs.x.org» lanza el trabajo en segundo plano (hasta 100 000 páginas); «sigue rastreando https://docs.x.org» reanuda el último sin terminar. Desde la herramienta, `crawl_docs` con `job=<id>` o `continue=true`. - Volver a rastrear la misma URL sustituye todos los lotes antiguos al terminar el primer lote nuevo. - API: `GET /api/rag/crawls`, `POST /api/rag/crawls/{id}/pause`, `POST /api/rag/crawls/{id}/resume` y `DELETE /api/rag/crawls/{id}?docs=true`.

Seguridad y límites: solo direcciones públicas (se comprueba en cada petición y tras cada redirección; `rag.allow_private_urls: true` permite la red local), 3 MB por página, 6 millones de caracteres por documento o lote y 15 minutos por tanda (un trabajo por lotes sigue en la siguiente tanda). Las páginas que solo muestran contenido con JavaScript se omiten por tener poco texto. La herramienta tiene **riesgo medio** (accede a internet): con la política por defecto el usuario la aprueba en una tarjeta.

URL → PDF estructurado → conocimiento

Pide en el chat *«Procesa https://... y hazme un PDF»* (o usa *Procesar URL* en la Biblioteca):

1. **Descarga** (solo direcciones públicas; se bloquean IPs locales también tras redirecciones; máx. 8 MB).
2. **Extracción estructurada**: título, descripción, autor, fecha, idioma, sitio; jerarquía de secciones; párrafos, listas, tablas, bloques de código, citas; imágenes y enlaces. Prioriza `<article>`/`<main>` y descarta navegación, pies, formularios, banners de cookies, etc.
3. **Resumen y puntos clave** con el LLM (o resumen extractivo sin LLM).
4. **PDF maquetado**: portada, índice con números de página, marcadores PDF navegables, resumen, puntos clave, contenido, galería de imágenes incrustadas (hasta 8), enlaces y metadatos. Fuentes Unicode del sistema (Segoe UI/DejaVu/Arial/Roboto) con respaldo automático.
5. **Publicación** al usuario: tarjeta de PDF en el chat (`data/outputs/docs/`).
6. **Archivo en el RAG**: el PDF generado se indexa en la biblioteca.
7. **Asimilación**: el resumen y los puntos clave pasan a la memoria a largo plazo; el documento se añade al grafo de conocimiento (`ha_leido`, `trata_de`, `publicado_en`, `escrito_por`, `contiene`) y aparece en el avatar.

Medido en el equipo de desarrollo (CPU i3, Qwen3-VL 2B): artículo de Wikipedia de 4 540 palabras → PDF de 25 páginas, 16 secciones, 8 imágenes, 74 fragmentos RAG y 14 conocimientos en ~68 s.

La herramienta tiene **riesgo medio** (accede a internet): con la política por defecto el usuario la aprueba en una tarjeta.

Dispositivos: luces, reloj y avatar de bolsillo

Nexus-Office reparte su estado (en línea, escuchando, pensando, usando una herramienta, hablando, hecho, error) y lo que hace cada agente a tres dispositivos baratos que se conectan por Wi-Fi a tu ordenador. Todo se graba y configura **sin internet**: los binarios y el grabador vienen en el paquete.

Dispositivo	Placa	Qué hace	Binario (`firmware/bin/`)
NexusLED	Toda la familia ESP con Wi-Fi: ESP8266 (ESP-01/01S, ESP-12, NodeMCU, Wemos D1 mini), ESP32, S2, S3, C3, C5 y C6, con tiras WS2812, WS2812B o SK6812 (RGB y RGBW)	Luces que muestran el estado de Nexus (vúmetro con su voz al hablar), 23 efectos, 11 paletas, hasta 4 tiras y 1500 LED (600 en el ESP8266)	`nexusled-esp8266.bin` (1 MB), `-esp8266-4m`, `-esp8266-512k`, `-esp32`, `-esp32s2`, `-esp32s3`, `-esp32c3`, `-esp32c5`, `-esp32c6`
NexusWatch	ESP32-2424S012C-Y / (B): ESP32-C3 con pantalla redonda GC9A01 de 1,28" y táctil CST816S	Reloj con el avatar animado, qué hace cada agente y los modos	`nexuswatch-esp32c3.bin`
NexusPico	Raspberry Pi Pico W + pantalla de tinta Waveshare 2,13" V3 o V4 (la del pwnagotchi)	Avatar de bolsillo con caras al estilo pwnagotchi según el estado	`nexuspico-picow.uf2`

Grabar el firmware

Desde Nexus-Office: *Dispositivos → Grabar firmware*. Conecta la placa por USB, elige el dispositivo y el modelo de ESP32, escribe la Wi-Fi y pulsa **GRABAR**. Nexus graba el binario, le pone la Wi-Fi, su propia dirección y la clave de red, y el dispositivo aparece en *Conectados ahora*. Para el Pico W, conéctalo con **BOOTSEL** pulsado.

Nexus-Office graba con su propio grabador en C++ (nexus-flash), sin esptool ni Python: detecta el chip, elige el binario, lo graba, lo comprueba y le manda la configuración. Si el adaptador USB de la placa (CH340, CP210x o FTDI) no tiene driver, **INSTALAR DRIVERS** lo instala.

ESP-01 y placas sin reinicio automático: con un adaptador USB-serie de 3,3 V, une GPIO0 a GND y dale corriente; Nexus espera 20 s a que entre en modo de carga. Al terminar, suelta GPIO0 y vuelve a darle corriente. El ESP-01S y cualquier ESP8266 de 1 MB o más usan `nexusled-esp8266.bin`; el ESP-01 azul antiguo de 512 KB, `-esp8266-512k` (sin actualización por Wi-Fi); NodeMCU y Wemos pueden usar `-esp8266-4m`.

Con la orden `nexus-flash` (en `firmware/` de la carpeta de instalación o compilada desde `firmware/flasher`):

```
nexus-flash puertos
nexus-flash luces --wifi MiRed MiClave --leds 60            # GPIO 16 en ESP32, GPIO 2 en ESP8266
nexus-flash reloj --wifi MiRed MiClave --nexus 192.168.1.10:8775 CLAVE_DE_RED
nexus-flash pico  --wifi MiRed MiClave --nexus 192.168.1.10:8775 CLAVE_DE_RED
```

Con el script de Python (`firmware/flash.py`, en la edición Python):

```
python firmware/flash.py puertos
python firmware/flash.py luces --wifi MiRed MiClave --leds 60 --pin 16
python firmware/flash.py reloj --wifi MiRed MiClave --nexus 192.168.1.10:8775 CLAVE_DE_RED
python firmware/flash.py pico  --wifi MiRed MiClave --nexus 192.168.1.10:8775 CLAVE_DE_RED
python firmware/flash.py config reloj --wifi OtraRed OtraClave      # solo cambiar la configuración
```

Los dos reconocen el chip y eligen su `.bin`. La *clave de red* es la de *Red COOP → Conectar dispositivos*, y Nexus-Office tiene que escuchar en la red local.

A mano: `esptool --chip esp32s3 write_flash 0x0 nexusled-esp32s3.bin` (los `.bin` son imágenes completas y van en la dirección `0x0`) o la web https://espressif.github.io/esptool-js/. Para el Pico W, copia el `.uf2` a la unidad `RPI-RP2`. `firmware/bin/firmware.json` trae la versión y la huella SHA-256 de cada binario.

Sin el script, cada dispositivo sin Wi-Fi crea su propia red (`NexusLED-XXXX`, `NexusWatch-XXXX` con clave `nexuswatch`, `NexusPico-XXXX` con clave `nexuspico`) con una página de configuración en http://192.168.4.1.

Luces NexusLED

- *Dispositivos → Luces*: **BUSCAR** encuentra las luces de tu red (mDNS y UDP) o se añaden por IP. Para cada una: encender, brillo, efecto, paleta, color y si sigue el estado de Nexus.
- Conexión: DIN de la tira al GPIO 16 (en el ESP32-C3, por ejemplo el 8 o el 10; en el ESP8266 el GPIO 2, que es D4 en NodeMCU y Wemos y el único libre en el ESP-01) con una resistencia de 330 Ω, y GND común entre el ESP32 y la fuente. Más detalles en `firmware/nexusled/README.md`.

Reloj NexusWatch

- **Inicio**: el avatar de Nexus animado según lo que hace, con un anillo del color del estado.
- Desliza a los lados: **Agentes** (qué hace cada uno ahora; toca uno para ver su escena y su tarea), **Modos** y **Info** (Wi-Fi, IP y Nexus al que está conectado; mantén pulsado para volver al portal de configuración).
- Baja el brillo a los 30 s y se apaga a los 2 min; un toque lo enciende.

Avatar NexusPico

Nexus genera una imagen por estado con el avatar y una cara al estilo pwnagotchi. El Pico las descarga una vez, las guarda y después solo pregunta el estado cada 2 s (refresco parcial, sin parpadeo). Si cambias el nombre del asistente o el estilo (`dispositivos.pico.estilo`: `avatar` o `caras`), las vuelve a descargar. Las imágenes se ven en *Dispositivos*. Pines (Pico-ePaper-2.13): RST GP12, DC GP8, CS GP9, CLK GP10, DIN GP11, BUSY GP13.

Modos

Un modo cambia de una vez la voz, las reuniones, el estilo de respuesta, el perfil de hardware y el brillo de las luces. Se elige en *Dispositivos*, desde el móvil o tocando en el reloj, y se aplica en todos a la vez.

Modo	Qué hace
Normal	Voz y luces como siempre
Manos libres	Responde siempre en voz alta
Silencio	Sin voz y luces tenues
Concentración	Sin reuniones automáticas ni voz; respuestas breves
Rendimiento	Perfil de hardware *Rendimiento*
Ahorro	Perfil de hardware *Ahorro*
Noche	Luces apagadas y sin voz

Un modo nunca cambia la seguridad ni la red. Se pueden añadir modos propios en `dispositivos.modos`.

API

`GET /api/dispositivos`, `GET` y `POST /api/dispositivos/estado`, `GET /api/dispositivos/reloj`, `POST /api/dispositivos/modo {modo}`, `GET /api/dispositivos/pico/manifiesto` y `/api/dispositivos/pico/{estado}.bin|.png`, `GET /api/dispositivos/leds/buscar`, `POST`, `PUT` y `DELETE /api/dispositivos/leds/...`, `GET /api/firmware`, `POST /api/firmware/grabar` y `GET /api/firmware/trabajo/{id}`.

Qué no se ha podido probar sin el hardware

Todo compila en CI y la lógica está probada en el PC (emulador de NexusLED, pantalla del reloj dibujada en un fichero y el código del Pico contra el servidor), pero falta probarlo en las placas reales: los tiempos de la pantalla GC9A01 y el táctil CST816S del reloj, el refresco de la tinta (V3 y V4) del Pico W y la salida de las tiras en cada modelo de ESP32.